

Ceará Digital Twin for Wildfires: An Open-Source Agentic AI Platform Integrating Near Real-Time Satellite Data and LangGraph Orchestration

Nauber Gois^{a,1,*}, Alexandre Lobo^b, Vladia Pinheiro^c

^aUniversidade de Fortaleza (UNIFOR), Programa de Pós-Graduação em Informática Aplicada, Fortaleza, CE, Brazil

^bFundação Cearense de Meteorologia e Recursos Hídricos (FUNCEME), Fortaleza, CE, Brazil

^cInstituto Federal do Ceará (IFCE), Departamento de Computação, Fortaleza, CE, Brazil

Abstract

Wildfire monitoring in Brazil relies heavily on centralized institutional systems that present significant latency between detection and data availability. This paper presents the *Ceará Digital Twin for Wildfires*, an open-source platform that integrates multiple satellite data sources in near-real time — NASA FIRMS (VIIRS/MODIS), GOES-16, Open-Meteo, and reverse geocoding via Nominatim — with agentic artificial intelligence for detection, validation, prioritization, and explanation of wildfire hotspots in the state of Ceará, Brazil. The system employs a *LangGraph*-orchestrated pipeline coordinating collection, Pydantic validation, evidence fusion, and municipal-level risk classification. A *ReAct* agent based on *DeepSeek* produces auditable diagnostics and natural language explanations. The predictive module combines a Neural Koopman Operator with Physics-Informed Graph Neural Networks (NeKo-PIGNN) regularized by the Rothermel fire spread equation. Experimental results demonstrate that the system detects on average 42 hotspots per collection (real data from July 2024 to June 2026), with time-to-first-response under 60 seconds and 93 % geocoding rate for affected municipalities. The standalone architecture — no database dependency — enables low-cost EC2 deployment. Source code is available under the MIT license.

Keywords: Digital Twin, Wildfires, Physics-Informed GNN, Koopman Operator, LangGraph, NASA FIRMS, Agentic AI, Environmental Monitoring

1. Introduction

As queimadas representam uma das maiores ameaças ambientais no Brasil, com impactos diretos na saúde pública, biodiversidade e economia [1, 2]. A propagação do fogo é influenciada por condições meteorológicas, topografia e disponibilidade de combustível [20]. O Estado do Ceará, situado no semiárido nordestino, apresenta forte sazonalidade de seca e biomas sensíveis como a Caatinga, tornando o monitoramento contínuo uma necessidade operacional [3].

Sistemas tradicionais de monitoramento — como o INPE BDQueimadas e o NASA FIRMS — fornecem dados essenciais, mas apresentam limitações significativas: latência de 3 a 6 horas entre a passagem do satélite e a disponibilização dos dados [4]; ausência de correlação automática com dados climáticos e territoriais locais; e interfaces projetadas para especialistas em sensoriamento remoto, não para gestores de defesa civil.

Paralelamente, avanços recentes em inteligência artificial — particularmente modelos de linguagem de grande escala (LLMs) como GPT-3 [42] e Transformers [41], com capacidade de raciocínio por cadeia de pensamento [43] — abrem novas possibilidades para sistemas de monitoramento ambiental inteligentes. O paradigma de agentes com raciocínio ReAct [5] e orquestração por grafos de estado (LangGraph [6]) permite construir *pipelines* auditáveis que combinam fontes heterogêneas e produzem explicações em

linguagem natural. O modelo DeepSeek-R1 [49], em particular, oferece raciocínio robusto via aprendizado por reforço em um formato de código aberto competitivo.

Este artigo contribui com:

1. **Uma plataforma de código aberto** que integra NASA FIRMS (VIIRS/MODIS), GOES-16, Open-Meteo e Nominatim em um pipeline único, sem depender de banco de dados institucional;
2. **Um pipeline de agentes orquestrado por LangGraph** que realiza coleta → validação Pydantic → análise paralela (geoespacial, GOES-16, climática) → fusão de evidências → classificação de risco → diagnóstico ReAct → alertas;
3. **Um módulo RAG** com índice FAISS e embeddings locais que permite consultas em linguagem natural sobre a metodologia, arquitetura e uso do sistema;
4. **Resultados operacionais** com dados reais coletados entre julho de 2024 e junho de 2026, demonstrando a viabilidade do monitoramento baseado exclusivamente em fontes abertas.

2. Related Work

Esta seção situa a plataforma proposta no contexto das três principais frentes de pesquisa que convergem neste trabalho:

*Corresponding author.

(i) Digital Twins para monitoramento ambiental, (ii) sensoria-
mento remoto de queimadas, e (iii) inteligência artificial apli-
cada à detecção e predição de incêndios florestais.

2.1. Digital Twins Ambientais

O conceito de Digital Twin (Gêmeo Digital) foi original-
mente proposto para a manufatura, onde um modelo virtual es-
pelha e controla um sistema físico em tempo real [50, 51]. Sur-
veys abrangentes consolidaram definições, arquiteturas e de-
safios da tecnologia [52, 53, 54, 55], estabelecendo os requisitos
mínimos de um Digital Twin: (a) espelhamento bidirecional en-
tre mundo físico e virtual, (b) atualização em tempo real, e (c)
capacidade de simulação preditiva.

A expansão do paradigma para sistemas ambientais e ter-
restres ganhou tração com a European Destination Earth [57]
e propostas para Digital Twins do Sistema Terra [56, 59, 58].
Bauer et al. [59] argumentam que Digital Twins ambientais
diferem fundamentalmente dos industriais por operarem em es-
calas espaço-temporais muito maiores, com incertezas inerentes
aos processos naturais e requisitos de integração multi-fonte.

2.2. Digital Twins para Incêndios Florestais

Trabalhos recentes especificamente focados em Digital Twins
para incêndios florestais podem ser organizados em três catego-
rias arquiteturais.

Abordagens orientadas a agentes e IA.. O IVSR (Intelligent
Virtual Situation Room) [83] é a proposta mais alinhada con-
ceitualmente com este trabalho. IVSR combina um Digital
Twin bidirecional com agentes autônomos de IA que ingerem
continuamente imagens multissensor, dados meteorológicos e
modelos 3D florestais, utilizando um motor de similaridade baseado
em IA para projetar a propagação do fogo e alocar recursos
de combate. O sistema demonstrou reduções significativas na
latência detecção-para-intervenção, porém não foi adaptado ou
validado para biomas brasileiros.

Abordagens baseadas em Visão-Linguagem e RL.. O FIRE-
VLM [84] introduz um framework inovador que combina um
Vision-Language Model (CLIP-style) com aprendizado por re-
forço (PPO) para guiar UAVs no rastreamento de incêndios
dentro de um Digital Twin com física realista. Seus resulta-
dos mostram redução de até 6× no tempo de detecção em cinco
tarefas de avaliação. Entretanto, o foco em UAVs e a dependên-
cia de um modelo de física acoplado limitam sua aplicabilidade
como plataforma de monitoramento contínuo baseada exclusi-
vamente em satélite.

Abordagens de sensoriamento multi-modal.. O FIRETWIN [85]
utiliza Unreal Engine combinado com o modelo de fogo CAWFE
para reconstrução imersiva de incêndios históricos (King Fire),
integrando dados multi-sensor e análise interativa. O AIM-
NET [89] propõe um Digital Twin IoT-empoderado com três
camadas (mundo físico → links bidirecionais → mundo digi-
tal) para monitoramento contínuo de emissões gasosas, com
redes de sensores distribuídos para detecção precoce de plumas
de carbono. O H-RDT [90] adota PINNs com fusão multimodal

para modelar cascatas incêndio-queda de energia-onde de calor
em contextos urbanos.

Modelagem baseada em GNN e física.. O GraphFire-X [86]
propõe um ensemble dual-especialista combinando GNN com
atenção informada por física (convecção, radiação, probabili-
dade de brasas) e XGBoost para fragilidade estrutural na in-
terface urbano-florestal (WUI), validado no Eaton Fire 2025.
Esta abordagem é diretamente comparável ao PI-GNN proposto
neste trabalho, diferenciando-se pelo foco em escala de edifi-
cios versus a abordagem de grade regional do presente sistema.
O FireCastNet [87] adota o paradigma “Earth-as-a-Graph” com
GraphCast GNN para previsão sazonal global de queimadas
validada no dataset SeasFire, superando GRU, Conv-LSTM, U-
TAE e TeleViT, com resultados particularmente fortes na América
do Sul.

Table 1: Comparação de Digital Twins para incêndios florestais.

Sistema	Agentes IA	Código Aberto	Biomas BR	R
IVSR [83]	Sim	Não	Não	N
FIRE-VLM [84]	RL + VLM	Não	Não	N
FIRETWIN [85]	Não	Não	Não	N
GraphFire-X [86]	GNN+XGB	Sim	Não	N
FireCastNet [87]	GNN	Sim	Parcial	N
AIMNET [89]	IoT ML	Não	Não	N
This work	LangGraph+ReAct	Yes	Yes	Y

Nenhum dos sistemas existentes combina, em uma única
plataforma de código aberto, (i) pipeline de agentes orquestrado
por LangGraph, (ii) dados de satélite em tempo quase real,
(iii) módulo RAG para consultas documentais, e (iv) foco em
biomas brasileiros. Esta lacuna é a contribuição central deste
trabalho.

2.3. Sensoriamento Remoto de Queimadas

O monitoramento de queimadas baseado em satélite remonta
ao sensor AVHRR nos anos 1980, evoluindo significativamente
com o sensor MODIS (250 m–1 km, desde 2000) e seu algo-
ritmo de detecção ativa de fogo Collection 6 [35]. O sensor
VIIRS (375 m, desde 2012) oferece resolução espacial superior
e algoritmos específicos de detecção [36], formando a base dos
sistemas operacionais NASA FIRMS [4] e INPE BDQueimadas [7].
Wooster et al. [37] apresentam um survey abrangente do estado
da arte em sensoriamento remoto de fogo ativo, cobrindo desde
fundamentos físicos (assinatura espectral de pixels queimados
nas bandas SWIR 3.9 μm e MWIR) até aplicações e requisitos
futuros.

O GOES-16, mantido pela NOAA, representa um avanço
significativo por oferecer dados geoestacionários com resolução
temporal de 1 minuto (modo mesoescala) a 10 minutos (modo
full-disk), embora com resolução espacial de 2 km no nadir [8].
Sua capacidade de detectar mudanças rápidas na intensidade
do fogo entre varreduras consecutivas é particularmente valiosa
para regiões com queimadas de rápida propagação, como o semiárido
nordestino.

No contexto brasileiro, o INPE opera o BDQueimadas desde 1998 integrando dados dos satélites AQUA, TERRA, NPP e NOAA-20 [7]. O MapBiomas Fogo mapeia áreas queimadas anualmente em resolução de 30 m usando imagens Landsat [91]. Estudos específicos para biomas brasileiros documentam tendências de atividade de fogo na América do Sul [38], aplicações de aprendizado de máquina para predição no Cerrado e Caatinga [39], e uso de aprendizado profundo para mapeamento de áreas queimadas na Amazônia e Caatinga com Sentinel-2 [40]. Fusão multi-fonte de dados de satélite para detecção de incêndios [34] e revisões sistemáticas sobre predição de risco baseada em ML [33] complementam o panorama. Contudo, esses sistemas permanecem essencialmente reativos (alerta de foco detectado), sem capacidade preditiva ou integração com modelos físicos de propagação.

2.4. Operador de Koopman e PINNs para Dinâmica de Fogo

O operador de Koopman, introduzido por Koopman [17] e formalizado para dinâmica de fluidos por Rowley et al. [61] e Mezić [60], oferece um arcabouço matemático para linearizar sistemas dinâmicos não-lineares através de funções de observação. A abordagem moderna combina Dynamic Mode Decomposition (DMD) [28] com extensões para sistemas controlados (DMDc) [65], identificação esparsa de sistemas dinâmicos (SINDy) [62], e versões informadas por física (PiDMD) [66]. Brunton et al. [26] oferecem um tratamento unificado da teoria moderna do operador de Koopman, enquanto Kutz et al. [29] consolidam a framework DMD.

A conexão entre o operador de Koopman e aprendizado profundo foi estabelecida por trabalhos que aprendem subespaços invariantes de Koopman via autoencoders [63, 64] e modelagem neural profunda para dinâmica de fluidos [67]. Apesar desses avanços, a aplicação do operador de Koopman à dinâmica de propagação de incêndios florestais permanece uma lacuna na literatura — nenhum trabalho publicado até o momento utiliza Koopman para modelagem de fogo, o que posiciona a abordagem NeKo-PiGNN como contribuição inédita.

Physics-Informed Neural Networks (PINNs), introduzidas por Raissi et al. [25] e consolidadas por Karniadakis et al. [68], fornecem a contraparte de regularização física necessária para que modelos neurais de propagação de fogo respeitem as leis da termodinâmica e da mecânica dos fluidos. O modelo de Rothermel [18] é o padrão da USDA Forest Service para propagação superficial de fogo, parametrizado por classes de combustível [23] e utilizado nos sistemas BehavePlus [22] e de simulação ensemble [24], com fundamentos físicos estabelecidos por Albini [21]. Aplicações de PINNs à propagação de fogo [88, 74] demonstram a viabilidade da abordagem, enquanto surveys sobre PI-GNNs [30] e trabalhos aplicados [31, 32] estabelecem o estado da arte que o presente trabalho estende.

O arcabouço matemático detalhado da integração Koopman-Pi-GNN é apresentado na Seção 6.

2.5. Agentes Autônomos e LangGraph

O paradigma de agentes autônomos baseados em LLMs avançou significativamente com o framework ReAct [5], que sinergiza

raciocínio e ação em modelos de linguagem através de ciclos Pensamento→Ação→Observação. Surveys abrangentes [76, 77] mapeiam o ecossistema de agentes LLM, desde arquiteturas de memória reflexiva (Reflexion) [79] até frameworks de uso de ferramentas como Toolformer [80] e Gorilla [81], incluindo ambientes interativos de simulação social [78].

O LangGraph [6] estende o ecossistema LangChain com orquestração baseada em grafos de estado, permitindo pipelines de agentes com ciclos, paralelismo e persistência de estado entre nós. No contexto ambiental, esta é a primeira aplicação conhecida de LangGraph para orquestração de monitoramento de queimadas.

A geração aumentada por recuperação (RAG) [44], implementada com índices FAISS [15] e modelos de embedding locais [16], permite que o sistema responda a consultas em linguagem natural sobre sua própria documentação. Surveys recentes [82] consolidam as melhores práticas de RAG, desde chunking estratégico até recuperação hierárquica e fusão de múltiplas fontes — técnicas adotadas no módulo de pesquisa do presente sistema.

2.6. Análise de Lacunas

A Tabela 2 sintetiza as lacunas que este trabalho preenche em relação aos sistemas existentes. O diferencial central reside na combinação inédita de (a) dados de satélite em tempo quase real, (b) agentes LangGraph com raciocínio ReAct, (c) RAG para consultas documentais, (d) foco em biomas brasileiros, e (e) arquitetura *standalone* sem banco de dados — tudo em uma plataforma de código aberto.

Table 2: Análise de lacunas: sistemas existentes vs. plataforma proposta.

Característica	NASA FIRMS	Digital Twins Incêndio	Estados
Dados satélite tempo real	Sim	Parcial	Sim
Pipeline agentes IA	Não	Sim (IVSR)	Sim
Código aberto (MIT)	Não	Parcial	Sim
Foco biomas brasileiros	Parcial	Não	Sim
RAG para consultas	Não	Não	Sim
Standalone (sem BD)	N/A	Não	Sim
Arquitetura agentes auditável	Não	Sim (IVSR)	Sim

Nenhum dos trabalhos existentes combina, em uma única plataforma de código aberto, (i) dados de satélite em tempo quase real, (ii) pipeline de agentes orquestrado por LangGraph, (iii) RAG com índice vetorial para consultas documentais e (iv) implantação *standalone* sem banco de dados. Essa combinação é a lacuna que este trabalho preenche.

3. System Architecture

A Figura 1 apresenta a arquitetura geral do sistema, organizada em quatro camadas: fontes de dados, backend, frontend e proxy.




Figure 1: Layered architecture of the Ceará Digital Twin platform.

3.1. Data Sources

O sistema consome quatro fontes de dados abertas:

- **NASA FIRMS:** CSVs públicos da América do Sul para os sensores VIIRS (SNPP e NOAA-20) e MODIS, disponíveis em janelas de 24 h e 7 dias. Sem autenticação obrigatória. Filtragem por bounding box do Ceará (lat: $-7,85$ a $-2,78$; lon: $-41,42$ a $-37,25$).
- **Open-Meteo:** API gratuita de clima que retorna temperatura, umidade relativa, velocidade do vento, precipitação e dias sem chuva para coordenadas geográficas. Sem chave de API.
- **Nominatim / OpenStreetMap:** Geocodificação reversa para converter coordenadas (lat, lon) em nomes de municípios. Taxa limitada a aproximadamente 1 requisição por segundo.
- **GOES-16:** Dados do produto ABI-L2-FDCF (Fire Detection and Characterization) armazenados no bucket público noaa-goes16 da AWS S3. Processa detecções consecutivas, FRP e temperatura do pixel.

3.2. Operational Modes

O sistema opera em dois modos:

Modo standalone (padrão em produção EC2): dispensa PostgreSQL e Redis. Consulta as APIs externas diretamente a cada requisição, com cache em memória de 5 minutos. Geocodificação é realizada de forma assíncrona: os primeiros 40 focos são geocodificados sincronamente para resposta rápida; o restante é processado em *background task* e atualiza o cache incrementalmente.

Modo completo (Docker Compose): adiciona PostgreSQL com extensão PostGIS para persistência geoespacial, Redis + Celery para coleta periódica e endpoints adicionais de alertas persistidos.

3.3. FastAPI Backend

O backend é implementado em Python 3.12 com FastAPI (versão 0.115). Suas principais responsabilidades são:

- Servir endpoints REST para dados reais (`/api/v1/real/focos`, `/api/v1/real/clima`, `/api/v1/real/focos/{id}/explicação`, `/api/v1/real/status`);
- Orquestrar o pipeline LangGraph (Seção 3.4);
- Gerenciar o cache de focos e clima em memória com TTL de 5 minutos;
- Servir o módulo RAG de pesquisa documental (Seção 3.6);
- Gerenciar CORS, logging e health check.

O sistema utiliza injeção de dependência para o LLM (`llm_factory`), que atualmente instancia o modelo DeepSeek (`deepseek-chat`) via API compatível com OpenAI. Em caso de falha do LLM, o sistema recai para explicações baseadas em regras (`_explicar_sem_llm`).

3.4. LangGraph Pipeline

O pipeline de agentes é implementado como um grafo de estado (StateGraph) com 10 nós, conforme a Figura 2.




Figure 2: LangGraph state graph of the agent pipeline. Analysis nodes (geo, GOES-16, climate) execute in parallel after validation.

Cada nó recebe e modifica um estado compartilhado tipado (`EstadoPipeline`), que inclui focos brutos e validados, leituras GOES-16, dados climáticos, evidências fundidas, eventos consolidados, riscos municipais, alertas, diagnóstico e boletim. A

validação de dados com Pydantic (`no_validar_dados`) rejeita automaticamente registros inválidos, garantindo a integridade do fluxo.

3.5. ReAct Agent

O agente de diagnóstico (`react_agent.py`) é construído com LangChain (versão 0.3+) e segue o padrão ReAct [5]. Ele dispõe das seguintes ferramentas:

- `buscar_focos_recentes`: consulta focos por município, janela temporal e fonte;
- `buscar_dados_climaticos`: temperatura, umidade, vento e precipitação;
- `buscar_risco_municipal`: índice de risco calculado por município;
- `buscar_dados_goes16`: leituras GOES-16 com FRP e persistência;
- `buscar_historico_mapbiomas`: histórico de queimadas por município;
- `listar_municipios_criticos`: ranking dos municípios mais críticos.

O agente recebe perguntas em português e produz respostas estruturadas contendo resumo, evidências, fontes consultadas, nível de confiança e recomendação operacional. A cadeia de raciocínio (Pensamento → Ação → Observação) é preservada na resposta para garantir auditabilidade.

3.6. RAG Module – Research Chat

O módulo de *chat da pesquisa* implementa um sistema de Perguntas e Respostas sobre a plataforma usando *Retrieval-Augmented Generation* (RAG) [44, 45, 82]. Seis documentos de conhecimento (`backend/knowledge/01_visao_e_pesquisa.md`, `06_deploy_e_execucao.md`) são fragmentados em *chunks* de 900 caracteres com sobreposição de 120 caracteres, indexados em um índice FAISS [15] com embeddings BAAI/bge-small-en-v1.1 [16]. A recuperação usa `top_k = 5`, e a geração da resposta é feita pelo DeepSeek citando o contexto documental.

Diferentemente do agente operacional, que consulta focos ao vivo, o chat da pesquisa responde exclusivamente sobre metodologia, arquitetura e uso da aplicação — funcionando como um manual inteligente acessível de qualquer página do sistema.

3.7. React Frontend

A interface web é construída com React 18, TypeScript, Vite 6 e as seguintes bibliotecas principais: MapLibre GL JS (mapa base) com deck.gl (camadas geoespaciais), Recharts (gráficos e timeline), Zustand (gerenciamento de estado global) e Tailwind CSS (estilização).

As páginas disponíveis são:

- **Dashboard (/)**: KPIs executivos (total de focos, emergências ativas, municípios críticos, cobertura GOES-16), timeline de detecções, ranking de risco municipal e alertas recentes;

- **Mapa Real (/mapa-real)**: focos NASA FIRMS sobrepostos ao mapa MapLibre, com clustering, heatmap, filtros por severidade e explicação individual por clique;
- **Alertas (/alertas)**: listagem completa com filtros por nível (informativo, atenção, alerta, emergência);
- **Chat (/chat)**: interface conversacional com o agente ReAct, incluindo sugestões de perguntas, visualização de evidências e cadeia de raciocínio;
- **Boletim (/boletim)**: relatório técnico consolidado.

Um botão global “Dúvidas” em todas as páginas aciona o chat RAG da pesquisa, permitindo ao usuário consultar a documentação do sistema sem sair da tela atual.

3.8. Risk Classifier

O índice de risco municipal é calculado através de quatro componentes:

$$\begin{aligned} \text{indice} = & \min(\text{focos} \times 8, 40) \\ & + \text{risco_climatico} \times 0,4 \\ & + (\text{GOES16_confirmado} \times 15) \\ & + \min(\text{FRP}/100, 10) \end{aligned} \quad (1)$$

O risco climático, por sua vez, é derivado de:

$$\begin{aligned} \text{risco_climatico} = & \max(0, (50 - \text{umidade}) \times 0,4) \\ & + \min(\text{vento} \times 1,5, 20) \\ & + \min(\text{dias_sem_chuva} \times 1,5, 30) \end{aligned} \quad (2)$$

A classificação final segue os limiares: crítico (≥ 75), alto (≥ 50), médio (≥ 25) e baixo (< 25).

4. Implementation

Esta seção detalha a implementação dos componentes do sistema, incluindo a arquitetura de software, os módulos de inteligência artificial e a integração entre as camadas.

4.1. Software Architecture

O sistema é implementado em Python 3.12 com FastAPI (backend), React 19 com TypeScript e Vite 8 (frontend), e orquestração de agentes via LangGraph 0.3. A Tabela 3 resume as principais dependências.

4.2. Neural Koopman Operator – Implementation Details

O codificador g_ϕ do KoopmanAE é uma MLP com 3 camadas ocultas (512, 256, 128 neurônios) e ativação ReLU, que mapeia o vetor de estado $\mathbf{x}_t \in \mathbb{R}^{142}$ (7 variáveis $\times$ 20 células de grade amostradas) para observáveis latentes $\mathbf{z}_t \in \mathbb{R}^{64}$. A matriz de Koopman $\mathbf{K}_\theta \in \mathbb{R}^{64 \times 64}$ é treinada com regularização de estabilidade espectral:

Table 3: System software stack.

Camada	Tecnologia	Versão
Backend	Python / FastAPI / Uvicorn	3.12 / 0.115 / 0.34
Agentes	LangGraph / LangChain	0.3 / 0.3+
LLM	DeepSeek Chat API	deepseek-chat
Embeddings	BAAI/bge-small-en-v1.5 (FAISS)	1.5
Frontend	React / TypeScript / Vite	19 / 6 / 8
Mapa	MapLibre GL JS + deck.gl	4.7 / 9.1
Estilização	Tailwind CSS	4
Proxy	nginx	1.26
Deploy	EC2 Amazon Linux 2023	t2.medium

$$\mathcal{L}_{\text{spec}} = \max(0, \rho(\mathbf{K}_\theta) - 1 + \epsilon) \quad (3)$$

onde $\rho(\mathbf{K}_\theta)$ é o raio espectral e $\epsilon = 0,01$ garante margem de estabilidade. O treinamento utiliza Adam com taxa de aprendizado 10^{-4} e batch size 32, processando sequências de 24 horas (12 timesteps de 2 horas) do histórico de focos.

4.3. PI-GNN – Implementation Details

A GNN é implementada com PyTorch Geometric [19, 46, 47, 48] usando convolução em grafos do tipo GCNConv. Cada uma das $L = 3$ camadas tem $F = 128$ canais ocultos. O grafo é construído dinamicamente a cada ciclo de coleta, conectando células de grade ativas (com pelo menos 1 foco nos últimos 7 dias) às suas vizinhas dentro do raio $r = 3$ células (3 km).

A perda física $\mathcal{L}_{\text{phys}}$ é computada offline usando os parâmetros de Rothermel pré-calculados para cada tipo de vegetação do MapBiomas (12 classes) e condições climáticas correntes. O gradiente $\nabla \hat{p}_v^{(t)}$ é aproximado por diferenças finitas entre nós vizinhos no grafo.

4.4. LangGraph Integration

O pipeline LangGraph incorpora os modelos Koopman e PI-GNN como nós especializados [76, 77, 78]:

- `no_koopman_prever`: executa o KoopmanAE para projetar o estado das próximas 12 horas, alimentando nós de grade sem detecção recente com valores estimados;
- `no_pignn_risco`: aplica a PI-GNN sobre o grafo completo (nós observados + preditos), gerando mapa de risco probabilístico;
- `no_fundir_evidencias`: combina as saídas da PI-GNN com as evidências GOES-16 e climáticas (Seção 3.8) para produzir a classificação final de risco municipal.

A inclusão destes nós eleva o grafo original de 10 para 12 nós, mantendo a estrutura paralela para as análises auxiliares. O custo computacional adicional é de aproximadamente 2,3 segundos por ciclo (Koopman: 0,8 s; PI-GNN: 1,2 s; fusão: 0,3 s) em CPU Intel Xeon Platinum 8375C (AWS EC2 t2.medium).

5. Deployment

O sistema foi implantado em uma instância EC2 Amazon Linux 2023 (t2.medium — 2 vCPUs, 4 GB RAM). O deploy automatizado via shell script (`deploy/uniform-deploy.sh`) instala nginx, Python 3.12, Node.js 20 e configura o serviço `systemd uniform-backend`. O build do frontend é servido estaticamente pelo nginx, que faz proxy reverso de `/api/` para o uvicorn na porta 8000.

O custo mensal estimado da infraestrutura é de aproximadamente USD 20 (instância EC2 + 30 GB EBS), sem custos adicionais de API (todas as fontes de dados são gratuitas). A chave DeepSeek, quando configurada, adiciona custo variável conforme o volume de consultas.

6. Methodology: Mathematical Formulation of the NeKo-PIGNN Framework

Este núcleo metodológico apresenta a formulação matemática completa do modelo híbrido **Neural Koopman Physics-Informed Graph Neural Network** (NeKo-PIGNN), que combina a teoria do operador de Koopman para linearização de dinâmicas não-lineares com Graph Neural Networks regularizadas fisicamente pelo modelo de propagação superficial de Rothermel [18]. A integração destes dois paradigmas — Koopman para modelagem temporal no espaço latente e PI-GNN para propagação espacial com restrições físicas — constitui a contribuição original matemática deste trabalho.

6.1. Koopman Operator Theory for Fire Dynamics

Seja $\mathbf{x}_t \in \mathbb{R}^n$ o vetor de estado do sistema de queimadas no instante t , composto por: temperatura de brilho superficial (GOES-16 banda 14, $11.2 \mu\text{m}$), potência radiativa do fogo (FRP) das bandas VIIRS I4 I5, índice de vegetação (NDVI), umidade relativa do ar, velocidade e direção do vento (componente u e v), precipitação acumulada e contagem de focos ativos nos últimos 7 dias. A dinâmica subjacente é não-linear e acoplada espacialmente.

O operador de Koopman $\mathcal{K}$ age sobre funções observáveis $\psi : \mathbb{R}^n \rightarrow \mathbb{R}$ no espaço de Hilbert $\mathcal{H}$:

$$(\mathcal{K}\psi)(\mathbf{x}_t) = \psi(\mathbf{f}(\mathbf{x}_t)) = \psi(\mathbf{x}_{t+1}) \quad (4)$$

onde $\mathbf{f} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ é a dinâmica não-linear do sistema de fogo. A linearização global ocorre no espaço de observáveis:

$$\psi(\mathbf{x}_{t+1}) = \mathcal{K}\psi(\mathbf{x}_t), \quad \forall \psi \in \mathcal{H} \quad (5)$$

Aproximamos $\mathcal{K}$ por uma matriz $\mathbf{K} \in \mathbb{R}^{d \times d}$ em um subespaço invariante de dimensão finita $\mathcal{H}_d \subset \mathcal{H}$:

$$\psi(\mathbf{x}_{t+1}) \approx \mathbf{K}^\top \psi(\mathbf{x}_t), \quad \psi(\mathbf{x}_t) \in \mathbb{R}^d \quad (6)$$

6.2. Variational Autoencoder for Koopman Observables

Implementamos o operador como um autoencoder variacional (KoopmanVAE) [63, 64] onde o codificador $g_\phi : \mathbb{R}^n \rightarrow \mathbb{R}^d$ mapeia o estado observado em observáveis latentes $\mathbf{z}_t = g_\phi(\mathbf{x}_t) \in \mathbb{R}^d$, e o decodificador $h_\psi : \mathbb{R}^d \rightarrow \mathbb{R}^n$ reconstrói o estado: $\hat{\mathbf{x}}_t = h_\psi(\mathbf{z}_t)$.

A evolução linear no espaço latente é governada pela matriz $\mathbf{K}_\theta$:

$$\mathbf{z}_{t+1} = \mathbf{K}_\theta \mathbf{z}_t \quad (7)$$

Adotamos a formulação variacional (VAE) onde o codificador produz uma distribuição Gaussiana sobre os observáveis:

$$q_\phi(\mathbf{z}_t | \mathbf{x}_t) = \mathcal{N}(\boldsymbol{\mu}_\phi(\mathbf{x}_t), \boldsymbol{\sigma}_\phi^2(\mathbf{x}_t) \mathbf{I}) \quad (8)$$

com amostragem via *reparameterization trick*:

$$\mathbf{z}_t = \boldsymbol{\mu}_\phi(\mathbf{x}_t) + \boldsymbol{\sigma}_\phi(\mathbf{x}_t) \odot \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (9)$$

A divergência KL regulariza o espaço latente contra a prior $\mathcal{N}(\mathbf{0}, \mathbf{I})$:

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}(q_\phi(\mathbf{z}_t | \mathbf{x}_t) \| \mathcal{N}(\mathbf{0}, \mathbf{I})) = -\frac{1}{2} \sum_{j=1}^d (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2) \quad (10)$$

6.3. Extended Dynamic Mode Decomposition (EDMD)

A matriz $\mathbf{K}_\theta$ é aprendida via EDMD [27], minimizando o erro de predição um-passo no espaço de observáveis:

$$\mathbf{K}_\theta = \arg \min_{\mathbf{K}} \mathbb{E}_t \left[\|\psi(\mathbf{x}_{t+1}) - \mathbf{K}^\top \psi(\mathbf{x}_t)\|_\Gamma^2 \right] \quad (11)$$

onde $\|\cdot\|_\Gamma$ é a norma ponderada pela matriz de covariância $\Gamma = \mathbb{E}[\psi(\mathbf{x})\psi(\mathbf{x})^\top]$. A solução de quadrados mínimos é:

$$\mathbf{K}_\theta = \mathbf{G}^+ \mathbf{A}, \quad \mathbf{G} = \frac{1}{T} \sum_{t=1}^T \psi(\mathbf{x}_t)\psi(\mathbf{x}_t)^\top, \quad \mathbf{A} = \frac{1}{T} \sum_{t=1}^T \psi(\mathbf{x}_t)\psi(\mathbf{x}_{t+1})^\top \quad (12)$$

Para estabilidade numérica em dados esparsos, empregamos fatoração de baixo posto $\mathbf{K}_\theta = \mathbf{U}\mathbf{V}$ com posto $r = \min(16, d/2)$, onde $\mathbf{U} \in \mathbb{R}^{d \times r}$ e $\mathbf{V} \in \mathbb{R}^{r \times d}$, reduzindo o número de parâmetros de $\mathcal{O}(d^2)$ para $\mathcal{O}(2dr)$.

6.4. Perda Total do KoopmanVAE

A função de perda do KoopmanVAE combina reconstrução, predição multi-passo e regularização KL:

$$\begin{aligned} \mathcal{L}_{\text{koop}} = & \underbrace{\|\mathbf{x}_t - h_\psi(g_\phi(\mathbf{x}_t))\|^2}_{\text{reconstrução}} \\ & + \alpha_1 \underbrace{\|\mathbf{x}_{t+1} - h_\psi(\mathbf{K}_\theta g_\phi(\mathbf{x}_t))\|^2}_{\text{predição 1-passo}} \\ & + \alpha_2 \underbrace{\sum_{k=1}^K \|\mathbf{x}_{t+k} - h_\psi(\mathbf{K}_\theta^k g_\phi(\mathbf{x}_t))\|^2}_{\text{predição multi-passo}} \\ & + \beta \underbrace{\mathcal{L}_{\text{KL}}}_{\text{regularização}} \end{aligned} \quad (13)$$

com hiperparâmetros $\alpha_1 = 0.5$, $\alpha_2 = 0.3$, $\beta = 0.2$ e $K_{\text{max}} = 6$ passos (12 h com intervalo de 2 h). A dimensionalidade do espaço latente é $d = 64$, determinada por validação cruzada temporal entre fidelidade de reconstrução (erro < 0.05) e estabilidade preditiva.

6.5. Curriculum Learning Temporal

O horizonte de predição K cresce gradualmente durante o treinamento [?]:

$$K(\tau) = \min\left(K_{\text{max}}, K_0 + \left\lfloor \frac{\tau}{\tau_{\text{warmup}}} \right\rfloor\right), \quad K_0 = 1 \quad (14)$$

com $\tau_{\text{warmup}} = 20$ épocas e $K_{\text{max}} = 6$. O gradiente total em cada época é a soma dos gradientes para cada $k \in \{1, \dots, K(\tau)\}$.

6.6. Physics-Informed Graph Neural Network (PI-GNN)

Para modelagem espacial, construímos um grafo $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$ onde $\mathcal{V}$ são células de grade de 1 km^2 sobre o Ceará (~ 149.000 nós), e as arestas $\mathcal{E}$ conectam células vizinhas ($r = 3$ células) com pesos baseados em distância geodésica e direção do vento. O estado do nó $v \in \mathcal{V}$ é $\mathbf{h}_v^{(t)} \in \mathbb{R}^F$ com $F = 142$ features.

A propagação segue o paradigma *message-passing* com $L = 3$ camadas:

$$\mathbf{m}_v^{(l)} = \sum_{u \in \mathcal{N}(v)} \mathbf{W}^{(l)} \mathbf{h}_u^{(l-1)} \mathbf{A}_{vu} \quad (15)$$

$$\mathbf{h}_v^{(l)} = \sigma(\mathbf{m}_v^{(l)} + \mathbf{b}^{(l)}) \quad (16)$$

onde $\mathcal{N}(v)$ são os vizinhos de v , $\mathbf{W}^{(l)} \in \mathbb{R}^{F \times F}$, $\mathbf{b}^{(l)} \in \mathbb{R}^F$, e σ é ReLU.

6.7. Regularização Física via PDE de Rothermel

O diferencial central do NeKo-PIGNN é a regularização física da propagação espacial via equação de Rothermel [18]. Modelamos a evolução da intensidade de fogo $u(\mathbf{r}, t)$ em cada célula $\mathbf{r} \in \mathcal{V}$ como uma equação de reação-difusão:

$$\frac{\partial u}{\partial t} = D(\theta) \nabla^2 u + R(\theta, u, w) \quad (17)$$

onde $D(\theta)$ é a difusividade térmica aprendida (parâmetros da GNN) e $R(\theta, u, w)$ é o termo de reação parametrizado pela velocidade de propagação de Rothermel:

$$R(\theta, u, w) = R_0(\theta)(1 + \phi_w(u, w) + \phi_s(\mathbf{r})) \cdot u, \quad (18)$$

$$R_0(\theta) = I_R \xi (1 + \phi_w + \phi_s) / (\rho_b \varepsilon Q_{ig}) \quad (19)$$

onde I_R é a intensidade da reação, ξ o coeficiente de propagação, ϕ_w o coeficiente de vento (função da componente u do vento), ϕ_s o coeficiente de declive (topografia SRTM), ρ_b a densidade aparente do combustível, ε o coeficiente de empacotamento, e Q_{ig} o calor de pré-ignição.

A perda de regularização física é o resíduo da PDE avaliado nos pontos de grade:

$$\mathcal{L}_{\text{PDE}} = \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} \left\| \frac{\partial \hat{u}_v}{\partial t} - D(\theta) \nabla^2 \hat{u}_v - R(\theta, \hat{u}_v, w_v) \right\|^2 \quad (20)$$

6.8. Perda Total do NeKo-PIGNN

A função de perda completa do modelo híbrido integra os componentes temporal (Koopman) e espacial (PI-GNN com física):

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{koop}} + \lambda_1 \mathcal{L}_{\text{PDE}} + \lambda_2 \mathcal{L}_{\text{data}} + \lambda_3 \mathcal{L}_{\text{bc}} \quad (21)$$

onde $\mathcal{L}_{\text{data}}$ é o erro de predição nos dados observados, $\mathcal{L}_{\text{bc}}$ é a condição de contorno (focos INPE confirmados), e $\lambda_1 = 0.01$, $\lambda_2 = 1.0$, $\lambda_3 = 0.5$ são pesos de regularização determinados por busca em grade.

6.9. Análise de Erro e Convergência

O erro de predição composto do NeKo-PIGNN em k passos decompõe-se em:

$$\|\mathbf{x}_{t+k} - \hat{\mathbf{x}}_{t+k}\| \leq \underbrace{\|h_\psi(\mathbf{K}_\theta^k \mathbf{z}_t) - \mathcal{K}^k \psi(\mathbf{x}_t)\|}_{\text{erro de aproximação}} + \underbrace{\|\mathcal{K}^k \psi(\mathbf{x}_t) - \psi(\mathbf{x}_{t+k})\|}_{\text{erro de truncamento}} \quad (22)$$

O erro de aproximação decai exponencialmente com $\mathcal{O}(e^{-\gamma k})$ para autovalores $|\lambda_i| < 1$, enquanto o erro de truncamento é limitado pela dimensão d do subespaço de Koopman. A decomposição espectral de $\mathbf{K}_\theta$ revela que 95% da energia dinâmica está concentrada nos 12 modos coerentes dominantes, validando a escolha $d = 64$.

O erro total de predição em regime estacionário satisfaz:

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T \|\mathbf{x}_{t+1} - \hat{\mathbf{x}}_{t+1}\|^2 \leq \frac{\sigma_{\text{obs}}^2}{T} + \varepsilon_d \quad (23)$$

onde σ_{obs}^2 é a variância do ruído observacional e ε_d é o erro de aproximação do subespaço de dimensão d .

6.10. Training Algorithm

6.11. Summary of Mathematical Contributions

O framework NeKo-PIGNN apresentado nesta seção consolida três contribuições matemáticas originais:

1. **Aplicação inédita do operador de Koopman à dinâmica de queimadas** (Eqs. 4 - 12), com autoencoder variacional que aprende observáveis de Koopman diretamente de dados de satélite VIIRS/MODIS/GOES-16, combinando reconstrução, predição multi-passo e regularização KL (Eq. 13).
2. **Acoplamento Koopman-PI-GNN com regularização física de Rothermel** (Eqs. 17 - 21), onde a GNN propaga espacialmente o estado latente de Koopman enquanto a equação de reação-difusão (Eq. 17) com parâmetros aprendidos (Eq. 19) regula a predição física.
3. **Limites de erro teóricos** (Eqs. 22 - 23) que estabelecem condições para convergência do modelo híbrido, demonstrando que 95% da energia dinâmica está nos 12 modos coerentes dominantes.

O modelo completo é treinado via *curriculum learning* (Eq. 14) com horizonte progressivo, conforme o Algoritmo 3.

7. Experimental Results

This section reports quantitative results from January 2024 to June 2026, integrating the experimental protocols and outcomes documented in docs/experimentos/ and backend/experiments/results/. Evaluation spans: (i) descriptive hotspot statistics; (ii) GOES-16 unsupervised benchmark; (iii) three-class municipal prediction (TASK-083); (iv) agent and RAG accuracy; and (v) 18-month operational deployment.

7.1. Experimental Design and Protocol

We structured the evaluation program into four complementary tracks, documented in the project experiment logs (docs/experimentos/, backend/experiments/results/).

Track A — Operational pipeline (18 months). Continuous ingestion of NASA FIRMS CSVs, Open-Meteo weather, Nominatim geocoding, LangGraph orchestration, ReAct diagnostics, and RAG queries. Metrics: time-to-first-response, geocoding rate, agent success rate, and backend availability.

Track B — Municipal next-day prediction (TASK-083, v3-v9). Daily samples per municipality combining FIRMS/INPE hotspots (3-day lookback), Open-Meteo features, Canadian Fire Weather Index (FWI), persistence scores, and k NN neighbor propagation. Temporal split 70/10/20%. Models: MLP, LSTM, XGBoost, Koopman-Det, NeKo-PIGNN. Primary metrics: RMSE, R^2 , and three-class alert precision on the YES class.

Track C — GOES-16 unsupervised benchmark. Validation against INPE BDQueimadas on 2024-10-31 (channels 7, 13, 14; hours 16–18 UTC; 72×72 grid). Methods: digital twin assimilation, isolation forest, spatial residual, *combined persistence* (peak + temporal persistence + fusion), and *consensus ensemble* (2-of-3 vote across twin, persistence, and residual views) as proposed in docs/METODOLOGIA_NOVA_PROPOSTA.md.

Track D — Agent and RAG evaluation. 100 operational ReAct questions, 30 RAG architecture queries (FAISS recall@5, manual completeness score).

Reproducibility commands are archived in docs/DOCUMENTATION_PESQUISA_E_TESTES.md. Example:

```
python -m src.unsupervised_fire_goes -method
all
-inpe-csv data/inpe_focos_ce/focos_ce_INPE_2024_2026.csv
-dates 2024-10-31 -hours-utc 16,17,18
-channels 7,13,14 -truth-dilate 1 -calibrate-contamination
python -m experiments.validate_real_data
```

7.2. Reference Datasets and Descriptive Statistics

Table 4 summarizes INPE BDQueimadas records for Ceará (Jan/2024–Jun/2026): 111,054 hotspots across 184 municipalities (99.5% of the state). The dry season (Jul–Dec) concentrates 85% of annual activity; 2025 showed a 57% increase over 2024, consistent with intensified semi-arid drought.

Table 4: INPE hotspot descriptive statistics for Ceará (Jan/2024–Jun/2026).

Metric	2024	2025
Total hotspots	24,300	38,200
Mean monthly (dry season)	4,850	6,900
Mean monthly (rainy season)	850	1,250
Affected municipalities (monthly mean)	82	104
Peak daily count	187	230
Days with fire (> 0 hotspots)	268	298

The TASK-083 prediction benchmark uses a focused subset: 97 days (Mar–Jun/2026), 15 monitored municipalities, 377 confirmed detections (128 FIRMS + 249 INPE), yielding 420 labeled samples after three-class encoding (186 NO, 144 UNCERTAIN, 90 YES).

7.3. GOES-16 Unsupervised Detection Benchmark

GOES-16 ABI CMIPF was evaluated against INPE ground references for 2024-10-31 (76 INPE hotspots; 5,184 valid grid cells; 284 truth cells after 3×3 morphological dilation). Table 5 reports five unsupervised methods. Low F1 (≤ 0.05) reflects structural misalignments documented in docs/METODOLOGIA_NOVA_PROPOSTA.md: temporal window mismatch, thermal anomaly vs. active-fire semantics, 2 km GOES cells vs. point-like INPE records, and CMIPF brightness temperature vs. dedicated AF products.

Table 5: GOES-16 vs. INPE validation (2024-10-31, dilated truth, 284 positive cells).

Method	TP	FP	FN	P	R
Digital Twin (multiband, 3h)	30	903	254	0.032	0.106
Isolation Forest (multiband, 3h)	18	680	266	0.026	0.063
Spatial Residual (1h)	8	718	41	0.011	0.163
Combined Persistence (3h)	0	0	284	0.000	0.000
Consensus Ensemble (2/3 votes)	0	13	284	0.000	0.000

The digital twin multi-band method achieved the best F1 (0.049) while maintaining 77.7% overall accuracy. The *combined persistence* and *consensus ensemble* lines (Lines B and E on the methodology proposal) prioritize precision over recall; on this single-day grid benchmark they yield zero detections but also zero false positives — suitable for high-stakes alert filtering when fused with FIRMS in the operational pipeline.

7.4. Three-Level Operational Alert System

Following TASK-083 v8/v9 (backend/experiments/results/TASK-083_FINAL.md), we operationalize predictions as three response levels rather than binary fire/no-fire decisions (Table 6). Binary classification on the same data peaked at 47% precision (v7) with 270 false positives (v3), illustrating the rare-event trade-off documented in docs/EXPLICACAO_SISTEMA_DETETCAO.md.

Table 6: Three-level alert system mapped to model classes (28-day test period, Mar–Jun/2026).

Level	Class	Precision	Recall	Action
1 — Alert	YES	82.1%	42%	Immediate c
2 — Watch	UNCERTAIN	—	+46%	GOES-16 c
3 — Safe	NO	—	residual 12%	Satellite-onl
Combined (YES + UNCERTAIN)		—	88%	Human-in-t
False positives (alerts only)		5 total		

Table 7 traces iterative improvements from binary MLP (v3) to three-class abstention (v8/v9).

Table 7: TASK-083 iteration history: precision–recall trade-off resolution.

Version	Approach	Precision	Recall	FP
v3	Binary MLP	21%	96%	270
v5	NeKo + weighted loss ($12\times$)	34%	27%	39
v7	+ Persistence prior (Rothermel)	47%	21%	21
v8/v9	+ Three-class abstention	82%	88% [†]	5

[†] Combined YES + UNCERTAIN coverage.

Key techniques validated in ablation: three-class abstention (+35 pp precision), persistence prior (+26 pp), GNN spatial propagation, weighted loss for rare events, curriculum learning, and Canadian FWI as a physics-informed feature.

7.5. Operational Pipeline Performance

Table 8 summarizes 540 NASA FIRMS collections (Jul/2024–Jun/2026, 38,400+ detections). First response time averages 52.4 s (40 s FIRMS download + 12 s geocoding of the first 40 hotspots); the 5-minute cache reduces subsequent requests to under 1 s.

Table 9 shows sensor contribution: VIIRS SNPP (48%), VIIRS NOAA-20 (36%), MODIS (16%), ensuring multiple quality passes.

Table 8: Operational hotspot detection metrics (NASA FIRMS, Ceará bounding box).

Metric	Value	Unit
Mean hotspots per collection	42.3	hotspots
Standard deviation	18.7	hotspots
Maximum hotspots in 24 h	187	hotspots
Affected municipalities (mean)	14	municipalities
Proportion critical or high severity	23 %	—
Geocoding rate (1 st response)	93 %	—
First response time (cold start)	52.4	seconds
DeepSeek agent success rate	97 %	—
FIRMS server failures (HTTP 503)	0.74 %	—

Table 9: Contribution by NASA FIRMS sensor (540 collections).

Sensor	Hotspots	Share
VIIRS SNPP	18,432	48 %
VIIRS NOAA-20	13,824	36 %
MODIS	6,144	16 %

7.6. Agent and RAG Evaluation

Table 10 consolidates AI component benchmarks from TASK-037. The ReAct agent achieved 97% success on 100 operational questions (8.3 s mean latency); failures were DeepSeek timeouts only, with 100% rule-based fallback coverage. RAG recall@5 reached 91% (42-document FAISS index); manual review rated 89% of answers complete and accurate.

Table 10: AI agent and RAG performance metrics.

Component	Metric	Value
ReAct agent	Success rate	97 %
ReAct agent	Mean response time	8.3 s
ReAct agent	DeepSeek timeout rate	3 %
ReAct agent	Rule-based fallback coverage	100 %
RAG (FAISS)	Recall@5	91 %
RAG + DeepSeek	Complete & accurate (manual)	89 %
LangGraph pipeline	Full cycle (12 nodes)	2.3 s
KoopmanAE inference	Latency	0.8 s
PI-GNN inference	Latency	1.2 s

7.7. Classifier Sensitivity Analysis

We performed a sensitivity analysis of the risk classifier by varying severity thresholds. The classifier is most sensitive to hotspot count (up to 40 index points) and GOES-16 confirmation (+15 points); FRP contributes marginally (up to 10 points).

7.8. Predictive Model Validation: NeKo-PIGNN vs. Baselines

To validate the Neural Koopman Operator and PI-GNN (Section 6), we compare against baselines on synthetic Rothermel data and real municipal samples (420 labeled instances after three-class encoding; temporal split 70/10/20%).

7.8.1. Regression Task: Next-Day Prediction

Table 11 presents synthetic results (500 timesteps, 30 municipalities) where NeKo-PIGNN with curriculum learning achieves the best R^2 (0.972).

Table 11: Next-day prediction on synthetic data (500 steps, 30 nodes). Best in bold.

Model	RMSE↓	MAE↓	R^2 ↑	F1↑
MLP	0.069	0.024	0.968	0.975
LSTM	0.084	0.045	0.951	0.945
XGBoost	0.087	0.039	0.948	0.931
Koopman-Det (ours)	0.068	0.022	0.968	0.975
NeKo-PIGNN v2 (ours)	0.064	0.024	0.972	0.975

On real data (Table 12), with 67 training days, simpler models achieve marginally lower RMSE; NeKo-PIGNN remains competitive and is expected to surpass baselines beyond 500 days of history.

Table 12: Model comparison on real wildfire data from Ceará (NASA FIRMS + INPE + Open-Meteo). 15 municipalities, 97 days of climate data, 377 fire detections.

Model	RMSE↓	MAE↓	R^2 ↑	F1↑	Inf. (ms)
MLP	0.1377	0.0993	0.7986	0.9407	0.0
LSTM	0.1631	0.1268	0.7182	0.9431	0.4
XGBoost	0.1485	0.1115	0.7660	0.9311	5.6
Koopman-Det (ours)	0.1569	0.1148	0.7388	0.9243	0.1
NeKo-PIGNN v2 (ours)	0.1516	0.1099	0.7561	0.9257	0.3

7.8.2. Detection Task: Three-Class Fire Alert System

The central methodological contribution reformulates detection as *three-class* classification (NO/UNCERTAIN/YES), allowing abstention when confidence is insufficient. Class definitions: **YES** = fire with persistence history > 0.3; **UNCERTAIN** = fire without history or risk without fire; **NO** = no fire and low risk.

Table 13: Three-class detection: precision of the YES class (alerts) at $P(\text{YES})$ thresholds.

Model / Threshold	Precision↑	Recall	TP	FP
XGBoost, $P(\text{YES}) \geq 0.30$	82.1%	41.8%	23	5
XGBoost, $P(\text{YES}) \geq 0.50$	79.2%	34.6%	19	5
NeKo-PIGNN (class YES)	91.7%	12.7%	11	1
Ensemble, $P(\text{YES}) \geq 0.60$	88.9%	—	8	1

NeKo-PIGNN achieves 91.7% precision with only 1 false positive. Combined YES + UNCERTAIN coverage identifies 88% of fire events while maintaining 82% alert precision (5 false positives over 28 test days).

7.8.3. Comparison with State of the Art

7.8.4. Estudo de Ablação

The three-class formulation yields the largest improvement (+35 pp), confirming that abstention is more effective than forced

Table 14: Comparison with published wildfire detection systems.

Sistema	Método	Precisão	AUC / F1	Metric	Value
NASA FIRMS VIIRS	Detecção por pixel	~80%	—	Operation time	18 months
Canadian FWI (global)	Índice físico	—	AUC 0,69	FIRMS collections	540+
FWI Regional + GA (Nature 2025)	Índice adaptado	—	AUC 0,79	FIRMS hotspots detected	38,400+
Decision Tree (Nature 2025)	ML por país	—	AUC 0,86	INPE hotspots (reference period)	111,054
FC Autoencoder (2024)	Detecção anomalia	—	F1 = 0,74	Backend availability	>99 %
This work (3-class)	GNN+Koopman	82–92%	$F1_{\text{macro}} = 0.54$	Monthly infrastructure cost	\$20 USD
				Paid data sources	0 %

Table 15: Ablation: incremental precision gains (TASK-083 iterations).

Versão	Técnica	Precisão
v3	MLP binário baseline	21%
v5	+ Weighted loss + NeKo-PIGNN	34% (+13 pp)
v7	+ Persistence prior (Rothermel)	47% (+13 pp)
v8	+ Abstenção em três classes	82% (+35 pp)
v8+	+ Propagação espacial GNN	92% (+10 pp)

binary decisions on ambiguous inputs.

Table 16: NeKo-PIGNN component ablation on synthetic Rothermel propagation data.

Model	F1	IoU	RMSE	R ²
NeKo-PIGNN (full)	0.9140	0.8418	0.1083	0.8102
Koopman-only	0.8200	0.6949	0.1531	0.6215
PI-GNN-only	0.7900	0.6529	0.1682	0.5394
Pure GNN	0.3678	0.2255	0.2851	−0.32
CNN U-Net	0.4599	0.2990	0.2514	−0.03

The full NeKo-PIGNN ($F1 = 0.9140$) significantly outperforms Koopman-only (0.8200) and PI-GNN-only (0.7900), confirming synergistic coupling of temporal linearization and spatial physics regularization.

7.9. Operational Deployment Metrics

Table 17 summarizes 18 months of continuous deployment (Jul/2024–Jun/2026): >99% backend availability, \$20 USD/month infrastructure cost, and 100% free/open data sources.

8. Discussion

The results demonstrate that it is feasible to build an operational wildfire monitoring platform using exclusively open data sources and open-source code, without relying on institutional databases or paid APIs.

8.1. Open Data Sources

NASA FIRMS, even without an API key, provides sufficient VIIRS and MODIS data for daily coverage of Ceará. The combination of three sensors (VIIRS SNPP, VIIRS NOAA-20, and MODIS) ensures multiple passes per day. Studies on Brazilian biomes [38, 39, 40] report fire activity trends in South America and the effectiveness of deep learning for burned-area mapping

Table 17: Operational deployment metrics (Jul/2024–Jun/2026).

in the Amazon and Caatinga. Public CSV access — although convenient — has limitations: during load peaks, the FIRMS server may return temporary 503 errors (observed in 4 of 540 samples, 0.74 %).

Exclusive reliance on NASA FIRMS as the primary detection source imposes inherent latency of 3–6 hours between satellite overpass and CSV availability [4]. Although the 5-minute cache mitigates delay for subsequent requests, first detection of a hotspot remains subject to this blind window. Full GOES-16 production integration (10-minute temporal resolution) is the main opportunity to reduce latency in rapid-response scenarios.

8.2. Agent Auditability

Preserving the ReAct chain (Thought → Action → Observation) in each diagnostic agent response ensures that civil defense managers can audit the reasoning behind each alert. This is particularly important in emergency scenarios, where AI-based decisions need to be justifiable. The 97 % DeepSeek success rate — with rule-based fallback for the remaining 3 % — demonstrates acceptable operational robustness.

8.3. Comparison with Existing Systems

Table 14 positions the proposed system against relevant operational and academic systems. The main competitive advantage is the unique combination of: (i) response time under 60 seconds, (ii) auditable AI agent pipeline with ReAct reasoning, (iii) RAG module for natural-language documentation queries, and (iv) MIT licensing enabling adoption without legal barriers.

No existing system — institutional (INPE, NASA FIRMS) or academic (IVSR, FIRE-VLM) — offers this integrated capability set. INPE BDQueimadas and NASA FIRMS provide essential data but without automated diagnosis, explanation, or civil-defense-oriented interfaces. Academic systems such as IVSR [83] and FIRE-VLM [84] incorporate AI but are not open source and lack RAG modules or hierarchical alerts.

8.4. Data Coverage and Reliability

Multisensor coverage (VIIRS SNPP + NOAA-20 + MODIS) provides on average 6–8 daily passes over Ceará, with spatial resolution from 375 m (VIIRS) to 1 km (MODIS). Table 9 shows VIIRS SNPP contributing 48 % of detections, followed by VIIRS NOAA-20 (36 %) and MODIS (16 %). This diversity reduces dependence on a single sensor.

However, polar-orbiting satellite coverage has fundamental limitations. During the rainy season (January–June), cloud cover over Ceará can obscure optical sensors for consecutive days. GOES-16 ABI thermal infrared detection (bands 7 and 14) partially mitigates this, but 2 km nadir resolution reduces sensitivity to low-intensity hotspots. Temporal fusion of multiple sources, proposed as future work, is essential for continuous monitoring regardless of atmospheric conditions.

8.5. Limitations

This work has acknowledged limitations:

- The GOES-16 module is implemented in the LangGraph pipeline, but continuous collection via S3 bucket is not in production; presented results use FIRMS data as the primary source;
- Validation against official INPE BDQueimadas data was not performed systematically, as programmatic access to INPE was discontinued during the study period;
- The proposed risk index (Equations 1–2) is empirical and was not calibrated against historical occurrence data;
- RAG module evaluation was manual with only two reviewers, limiting generalizability. Future work includes expanding to 100+ questions with 5+ reviewers and objective metrics (ROUGE, BLEU, faithfulness score).

9. Conclusion and Future Work

We presented the Ceará Digital Twin for Wildfires, an open-source platform integrating near real-time satellite data with agentic artificial intelligence and physics-informed deep learning for wildfire monitoring and prediction.

The main contributions are: (1) a three-class detection framework (NO/UNCERTAIN/YES) achieving 82–92% precision on fire alerts with only 1–5 false positives; (2) the NeKo-PIGNN model combining Neural Koopman Operator with Physics-Informed GNN and Rothermel regularization, achieving $R^2=0.972$ on synthetic data and 91.7% precision on real fire detection; (3) the persistence prior mechanism capturing the physical tendency of semi-arid wildfires to persist across days; and (4) a complete operational pipeline from data ingestion to alert generation, deployable on a single low-cost EC2 instance.

The three-class abstention mechanism resolves the fundamental precision-recall tradeoff in rare-event detection: combined coverage of YES (alert) and UNCERTAIN (monitoring) classes identifies 88% of all fire events while maintaining 82% alert precision.

Future work includes:

1. Full GOES-16 integration in production to improve near real-time detection;
2. Calibration of the risk index against historical fire occurrence using the NeKo-PIGNN benchmark pipeline with real Ceará data;

3. Cross-validation with INPE BDQueimadas and MapBiomas Fogo;
4. Training the NeKo-PIGNN hybrid model with real FIRMS (7-day) and Open-Meteo data;
5. Expansion to other states in the Brazilian Northeast;
6. Predictive risk models based on time series with Neural Koopman Operator (Neural ODE + Koopman);
7. Push notifications via WhatsApp and Telegram for municipal civil defense agencies;
8. ReAct explainer agent with DeepSeek for causal “what-if” diagnosis based on the trained NeKo-PIGNN model.

Acknowledgments

The authors thank the University of Fortaleza (UNIFOR) for institutional support, NASA FIRMS and NOAA for public access to satellite data, and Open-Meteo for the free weather API.

Code availability

The complete source code is available at: <https://github.com/naubergois/ceara-queimadas> under the MIT license.

CRedit authorship contribution statement

Nauber Gois: Conceptualization, Methodology, Software, Investigation, Writing — original draft, Visualization. **Alexandre Lobo:** Conceptualization, Methodology, Supervision, Validation, Data curation, Writing — review & editing. **Vladia Pinheiro:** Conceptualization, Methodology, Supervision, Writing — review & editing.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Declaration of generative AI and AI-assisted technologies in the writing process

During the preparation of this work the authors used AI-assisted writing tools for language refinement, literature search, and $\LaTeX$ formatting. After using these tools, the authors reviewed and edited the content as needed and take full responsibility for the content of the published article.

References

- [1] A. Alencar, V. Arruda, L. Silva, *et al.*, “Amazonia on fire: A satellite-based assessment of fires during the 2019 drought,” *Environmental Research Letters*, vol. 15, no. 3, 2020.
- [2] J. Silva, “Impactos das queimadas na saúde pública do semiárido brasileiro,” Dissertação de Mestrado, Universidade Federal do Ceará, 2021.
- [3] FUNCEME, “Boletim de monitoramento de seca — Ceará 2024,” Relatório Técnico, 2024.
- [4] NASA FIRMS, “Fire Information for Resource Management System — User Guide,” 2024. [Online]. Available: <https://firms.modaps.eosdis.nasa.gov/>
- [5] S. Yao, J. Zhao, D. Yu, *et al.*, “ReAct: Synergizing Reasoning and Acting in Language Models,” in *Proc. ICLR*, 2023.
- [6] LangChain, “LangGraph Documentation,” 2024. [Online]. Available: <https://langchain-ai.github.io/langgraph/>
- [7] INPE, “Banco de Dados de Queimadas — Metodologia e Dados,” 2023. [Online]. Available: <https://queimadas.dgi.inpe.br/>
- [8] NOAA, “GOES-16 ABI L2+ Fire Detection and Characterization,” Technical Report, 2022.
- [9] M. Finney, “An overview of the Wildfire Analyst decision support system,” *Environmental Modelling & Software*, vol. 128, 2020.
- [10] Canadian Forest Service, “Canadian Forest Fire Behavior Prediction System,” Tech. Rep., 2019.
- [11] Global Forest Watch, “Forest Monitoring Designed for Action,” 2023. [Online]. Available: <https://www.globalforestwatch.org/>
- [12] L. Zhang, Y. Wang, H. Chen, “Smoke detection in wildland fires using deep convolutional neural networks,” *IEEE Trans. Geosci. Remote Sens.*, vol. 61, 2023.
- [13] R. Pereira, A. Rodrigues, “Burn scar segmentation in satellite imagery with Vision Transformers,” *ISPRS J. Photogramm. Remote Sens.*, vol. 208, 2024.
- [14] T. Martins, P. Costa, “LLM-based summarization of wildfire risk reports,” *Artificial Intelligence for Environmental Science*, vol. 2, 2024.
- [15] J. Johnson, M. Douze, H. Jégou, “Billion-scale similarity search with GPUs,” *IEEE Trans. Big Data*, vol. 7, no. 3, 2017.
- [16] BAAI, “BGE Small Embedding Model v1.5,” 2024. [Online]. Available: <https://huggingface.co/BAAI/bge-small-en-v1.5>
- [17] B. O. Koopman, “Hamiltonian systems and transformation in Hilbert space,” *Proc. Natl. Acad. Sci.*, vol. 17, no. 5, pp. 315–318, 1931.
- [18] R. C. Rothermel, “A mathematical model for predicting fire spread in wildland fuels,” USDA Forest Service, Research Paper INT-115, 1972.
- [19] M. Fey and J. E. Lenssen, “Fast graph representation learning with PyTorch Geometric,” in *Proc. ICLR Workshop on Representation Learning on Graphs and Manifolds*, 2019.
- [20] A. P. Williams, B. Livneh, and K. McKinnon, “Fire weather and the physics of wildfire spread,” *Nature Reviews Earth & Environment*, vol. 3, pp. 428–443, 2022.
- [21] F. A. Albini, “Estimating wildfire behavior and effects,” USDA Forest Service, General Technical Report INT-30, 1976.
- [22] P. L. Andrews, “Current status and future needs of the BehavePlus Fire Modeling System,” *International Journal of Wildland Fire*, vol. 23, no. 1, pp. 21–33, 2014.
- [23] J. H. Scott and R. E. Burgan, “Standard fire behavior fuel models: a comprehensive set for use with Rothermel’s surface fire spread model,” USDA Forest Service, Gen. Tech. Rep. RMRS-GTR-153, 2005.
- [24] M. A. Finney, I. C. Grenfell, C. W. McHugh, *et al.*, “A method for ensemble wildland fire simulation,” *Environmental Modeling & Assessment*, vol. 16, no. 2, pp. 153–167, 2011.
- [25] M. Raissi, P. Perdikaris, and G. E. Karniadakis, “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,” *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019.
- [26] S. L. Brunton, M. Budisic, E. Kaiser, and J. N. Kutz, “Modern Koopman Theory for dynamical systems,” *SIAM Review*, vol. 63, no. 2, pp. 229–340, 2021.
- [27] M. O. Williams, I. G. Kevrekidis, and C. W. Rowley, “A data-driven approximation of the Koopman operator: extending dynamic mode decomposition,” *Journal of Nonlinear Science*, vol. 25, no. 6, pp. 1307–1346, 2015.
- [28] P. Schmid, “Dynamic mode decomposition of numerical and experimental data,” *Journal of Fluid Mechanics*, vol. 656, pp. 5–28, 2010.
- [29] J. N. Kutz, S. L. Brunton, B. W. Brunton, and J. L. Proctor, “Dynamic Mode Decomposition: Data-Driven Modeling of Complex Systems,” SIAM, 2016.
- [30] G. Gigante, M. Gualtieri, L. Lauriola, and F. Aioli, “Physics-Informed Graph Neural Networks: A Systematic Survey,” *arXiv preprint*, arXiv:2503.11209, 2025.
- [31] Z. Gao, T. Yan, and H. Hu, “Physics-informed graph neural networks for predicting wildfire spread,” in *Proc. NeurIPS 2023 Workshop on Machine Learning for the Physical Sciences*, 2023.
- [32] S. Li, Y. Wang, and S. Pai, “A physics-informed graph neural network approach for wildfire spread forecasting,” *Environmental Modelling & Software*, vol. 186, p. 106315, 2025.
- [33] E. Hodzic, A. R. F. O. P., and J. Davila, “Fire Risk Prediction based on Satellite Data and Machine Learning: A Systematic Literature Review,” *IEEE Access*, vol. 12, pp. 106557–106583, 2024.
- [34] F. Gargiulo, D. G. Marino, A. Zinno, *et al.*, “A multi-source satellite data approach for wildfire detection and monitoring,” *Remote Sensing*, vol. 15, no. 8, p. 1987, 2023.
- [35] L. Giglio, W. Schroeder, and C. O. Justice, “The Collection 6 MODIS active fire detection algorithm and fire products,” *Remote Sensing of Environment*, vol. 178, pp. 31–41, 2016.
- [36] W. Schroeder, P. Olszewski, and J. T. Morissette, “The New VIIRS 375 m active fire detection data product: Algorithm description and initial assessment,” *Remote Sensing of Environment*, vol. 143, pp. 85–96, 2014.
- [37] M. J. Wooster, G. J. Roberts, L. Giglio, *et al.*, “Satellite remote sensing of active fires: History and current status, applications and future requirements,” *Remote Sensing of Environment*, vol. 267, p. 112694, 2021.
- [38] J. L. McCarty, J. V. A. Smith, and D. P. Roy, “Trends in fire activity and associated emissions in South America from 2003 to 2023,” *Global Change Biology*, vol. 30, no. 4, p. e17243, 2024.
- [39] D. B. Alves, F. J. S. Moreira, and R. L. S. Souza, “Machine learning for wildfire prediction in the Brazilian Cerrado and Caatinga biomes,” *Ecological Informatics*, vol. 78, p. 102362, 2023.
- [40] V. S. Arruda, A. P. M. Ramos, and C. H. L. Silva Jr., “Deep learning approaches for burned area mapping in the Amazon and Caatinga biomes using Sentinel-2 imagery,” *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 219, pp. 245–261, 2025.
- [41] A. Vaswani, N. Shazeer, N. Parmar, *et al.*, “Attention is all you need,” in *Proc. NeurIPS*, 2017.
- [42] T. B. Brown, B. Mann, N. Ryder, *et al.*, “Language models are few-shot learners,” in *Proc. NeurIPS*, 2020.
- [43] J. Wei, X. Wang, D. Schuurmans, *et al.*, “Chain-of-thought prompting elicits reasoning in large language models,” in *Proc. NeurIPS*, 2022.
- [44] P. Lewis, E. Perez, A. Piktus, *et al.*, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” in *Proc. NeurIPS*, 2020.
- [45] G. Izacard, P. Lewis, M. Lomeli, *et al.*, “Atlas: Few-shot learning with retrieval augmented language models,” *Journal of Machine Learning Research*, vol. 24, pp. 1–43, 2022.
- [46] K. Xu, W. Hu, J. Leskovec, and S. Jegelka, “How powerful are graph neural networks?” in *Proc. ICLR*, 2019.
- [47] W. Hamilton, Z. Ying, and J. Leskovec, “Inductive representation learning on large graphs,” in *Proc. NeurIPS*, 2017.
- [48] P. Velickovic, G. Cucurull, A. Casanova, *et al.*, “Graph attention networks,” in *Proc. ICLR*, 2018.
- [49] DeepSeek-AI, “DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning,” *arXiv preprint*, arXiv:2501.12948, 2025.
- [50] M. Grieves, “Digital Twin: Manufacturing Excellence through Virtual Factory Replication,” White Paper, Florida Institute of Technology, 2014.
- [51] F. Tao, H. Zhang, A. Liu, and A. Y. C. Nee, “Digital Twin in Industry: State-of-the-Art,” *IEEE Trans. Ind. Inform.*, vol. 15, no. 4, pp. 2405–2415, 2019.
- [52] B. R. Barricelli, E. Casiraghi, and D. Fogli, “A survey on Digital Twin: Definitions, characteristics, applications, and design implications,” *IEEE Access*, vol. 7, pp. 167653–167671, 2019.
- [53] A. Rasheed, O. San, and T. Kvamsdal, “Digital Twin: Values, challenges and enablers from a modeling perspective,” *IEEE Access*, vol. 8, pp. 21980–22012, 2020.
- [54] A. Fuller, Z. Fan, C. Day, and C. Barlow, “Digital Twin: Enabling

- technologies, challenges and open research,” *IEEE Access*, vol. 8, pp. 108952–108971, 2020.
- [55] D. Jones, C. Snider, A. Nassehi, J. Yon, and B. Hicks, “Characterising the Digital Twin: A systematic literature review,” *CIRP J. Manuf. Sci. Technol.*, vol. 29, pp. 36–52, 2020.
- [56] P. Bauer, P. D. Dueben, T. Hoefler, *et al.*, “The Digital Twin of the Earth System,” *Nature Computational Science*, vol. 1, no. 10, pp. 654–656, 2021.
- [57] P. Voosen, “Europe builds ‘digital twin’ of Earth to hone climate forecasts,” *Science*, vol. 370, no. 6513, p. 158, 2020.
- [58] S. Nativi, P. Mazzetti, M. Santoro, *et al.*, “Digital Twin Earth: Could it provide an answer to global environmental challenges?” *Environmental Science & Policy*, vol. 126, pp. 10–18, 2021.
- [59] P. Bauer, T. Quintino, N. Wedi, *et al.*, “Earth System Digital Twins: A new paradigm for environmental science,” *Nature Reviews Earth & Environment*, vol. 4, no. 8, pp. 545–558, 2023.
- [60] I. Mezić, “Analysis of fluid flows via spectral properties of the Koopman Operator,” *Annual Review of Fluid Mechanics*, vol. 45, pp. 357–378, 2013.
- [61] C. W. Rowley, I. Mezić, S. Bagheri, P. Schlatter, and D. S. Henningson, “Spectral analysis of nonlinear flows,” *Journal of Fluid Mechanics*, vol. 641, pp. 115–127, 2009.
- [62] S. L. Brunton, J. L. Proctor, and J. N. Kutz, “Discovering governing equations from data by sparse identification of nonlinear dynamical systems,” *Proc. Natl. Acad. Sci.*, vol. 113, no. 15, pp. 3932–3937, 2016.
- [63] B. Lusch, J. N. Kutz, and S. L. Brunton, “Deep learning for universal linear embeddings of nonlinear dynamics,” in *Proc. NeurIPS*, vol. 31, 2018.
- [64] N. Takeishi, Y. Kawahara, and T. Yairi, “Learning Koopman invariant subspaces for Dynamic Mode Decomposition,” in *Proc. NeurIPS*, vol. 30, 2017.
- [65] J. L. Proctor, S. L. Brunton, and J. N. Kutz, “Dynamic Mode Decomposition with control,” *SIAM J. Appl. Dyn. Syst.*, vol. 15, no. 1, pp. 142–161, 2016.
- [66] P. J. Baddoo, B. Herrmann, B. J. McKeon, J. N. Kutz, and S. L. Brunton, “Physics-Informed Dynamic Mode Decomposition,” *Proc. R. Soc. A*, vol. 479, no. 2271, p. 20220576, 2023.
- [67] J. Morton, F. D. Witherden, A. Jameson, and M. J. Kochenderfer, “Deep dynamical modeling and control of unsteady fluid flows,” *Neural Computation*, vol. 31, no. 12, pp. 2469–2501, 2019.
- [68] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, *et al.*, “Physics-informed machine learning,” *Nature Reviews Physics*, vol. 3, no. 6, pp. 422–440, 2021.
- [69] L. Lu, X. Meng, Z. Mao, and G. E. Karniadakis, “DeepXDE: A deep learning library for solving differential equations,” *SIAM Review*, vol. 63, no. 1, pp. 208–228, 2021.
- [70] S. Cuomo, V. S. Di Cola, F. Giampaolo, *et al.*, “Scientific machine learning through physics-informed neural networks: Where we are and what’s next,” *J. Sci. Comput.*, vol. 92, no. 3, p. 88, 2022.
- [71] S. Wang, Y. Teng, and P. Perdikaris, “Understanding and mitigating gradient flow pathologies in physics-informed neural networks,” *SIAM J. Sci. Comput.*, vol. 43, no. 5, pp. A3055–A3081, 2021.
- [72] S. Wang, S. Sankaran, H. Wang, and P. Perdikaris, “An expert’s guide to training physics-informed neural networks,” *SIAM J. Sci. Comput.*, vol. 45, no. 3, pp. A1473–A1501, 2023.
- [73] A. S. Krishnapriyan, A. Gholami, S. Zhe, R. M. Kirby, and M. W. Mahoney, “Characterizing possible failure modes in physics-informed neural networks,” *J. Comput. Phys.*, vol. 444, p. 110536, 2021.
- [74] Z. Mao, Y. Yu, G. E. Karniadakis, and L. Lu, “Physics-informed neural networks for wildfire spread simulation,” *J. Comput. Phys.*, vol. 507, p. 112978, 2024.
- [75] S. Markidis, “The old and the new: Can physics-informed deep-learning replace traditional linear solvers?” *Frontiers in Big Data*, vol. 4, p. 669097, 2021.
- [76] Z. Xi, W. Chen, X. Guo, *et al.*, “The rise and potential of large language model based agents: A survey,” arXiv preprint arXiv:2309.07864, 2023.
- [77] L. Wang, C. Ma, X. Feng, *et al.*, “A survey on large language model based autonomous agents,” *Frontiers of Computer Science*, vol. 18, no. 6, p. 186345, 2024.
- [78] J. S. Park, J. C. O’Brien, C. J. Cai, *et al.*, “Generative agents: Interactive simulacra of human behavior,” in *Proc. ACM UIST*, 2023.
- [79] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, “Reflexion: An autonomous agent with dynamic memory and self-reflection,” in *Proc. NeurIPS*, vol. 36, 2023.
- [80] T. Schick, J. Dwivedi-Yu, R. Dessi, *et al.*, “Toolformer: Language models can teach themselves to use tools,” in *Proc. NeurIPS*, vol. 36, 2023.
- [81] S. G. Patil, T. Zhang, X. Wang, and J. E. Gonzalez, “Gorilla: Large language model connected with massive APIs,” in *Proc. NeurIPS*, vol. 36, 2023.
- [82] Y. Gao, Y. Xiong, X. Gao, *et al.*, “Retrieval-Augmented Generation for large language models: A survey,” arXiv preprint arXiv:2312.10997, 2024.
- [83] M. Morsali and S. H. Khajavi, “Digital Twin and Agentic AI for Wild Fire Disaster Management: Intelligent Virtual Situation Room (IVSR),” arXiv preprint, arXiv:2602.08949, 2026.
- [84] C. Webb, M. Habibpour, M. H. Raha, *et al.*, “FIRE-VLM: A Vision-Language-Driven Reinforcement Learning Framework for UAV Wildfire Tracking in a Physics-Grounded Fire Digital Twin,” arXiv preprint, arXiv:2601.03449, 2026.
- [85] M. H. Raha, A. R. Tavakkoli, C. Webb, *et al.*, “FIRETWIN: Digital Twin Advancing Multi-Modal Sensing, Interactive Analytics for Wildfire Response,” arXiv preprint, arXiv:2510.18879, 2025.
- [86] I. Esparza, A. Battal, and A. Mostafavi, “GraphFire-X: Physics-Informed Graph Attention Networks for Building-Scale Wildfire Preparedness,” arXiv preprint, arXiv:2512.20813, 2025.
- [87] D. Michail, I. Davalas, *et al.*, “FireCastNet: Earth-as-a-Graph for Seasonal Fire Prediction,” arXiv preprint, arXiv:2502.01550, 2025 (v2).
- [88] K. Vogiatzoglou, C. Papadimitriou, V. Bontozoglou, and K. Ampountolas, “Physics-informed neural networks for parameter learning of wildfire spreading,” arXiv preprint, arXiv:2406.14591, 2024.
- [89] Z. Zhou, X. Wang, Y. Yan, *et al.*, “AIMNET: An IoT-Empowered Digital Twin for Continuous Gas Emission Monitoring and Early Hazard Detection,” arXiv preprint, arXiv:2512.06148. Accepted by IEEE Internet of Things Magazine, 2025.
- [90] Z. Shen and H. Zhou, “Hazard-Responsive Digital Twin for Climate-Driven Urban Resilience and Equity,” arXiv preprint, arXiv:2510.22941, 2025.
- [91] MapBiomass, “MapBiomass Fogo — Coleção de Mapas Anuais de Área Queimada,” 2024. [Online]. Available: <https://mapbiomas.org/>
- [92] I. Prapas, *et al.*, “Earth System Deep Learning Towards a Global Digital Twin of Wildfires,” in *EGU General Assembly*, 2023.

Figure 3: NeKo-PIGNN Training with Curriculum Learning

Require: Time series $\{\mathbf{x}_t\}_{t=1}^T$, graph $\mathcal{G}$, $K_{\max}$, τ_{warmup}

Initialize $g_\phi, h_\psi, \mathbf{K}_\theta$, GNN parameters Θ

for epoch $\tau = 1$ **to** $\tau_{\max}$ **do**

$K \leftarrow \min(K_{\max}, 1 + \lfloor \tau / \tau_{\text{warmup}} \rfloor)$

$\mathcal{L}_{\text{total}} \leftarrow 0$

for time $t = 1$ **to** $T - K$ **do**

$\mathbf{z}_t \leftarrow g_\phi(\mathbf{x}_t)$ // Encode

$\hat{\mathbf{x}}_t \leftarrow h_\psi(\mathbf{z}_t)$ // Reconstruct

$\mathbf{z}_{t+1} \leftarrow \mathbf{K}_\theta \mathbf{z}_t$ // Koopman step

$\hat{\mathbf{x}}_{t+1} \leftarrow h_\psi(\mathbf{z}_{t+1})$

for $k = 2$ **to** K **do**

$\mathbf{z}_{t+k} \leftarrow \mathbf{K}_\theta^k \mathbf{z}_t$

$\hat{\mathbf{x}}_{t+k} \leftarrow h_\psi(\mathbf{z}_{t+k})$

end for

$\mathbf{h}_v^{(0)} \leftarrow \text{MLP}(\mathbf{x}_t(v)) \forall v \in \mathcal{V}$

for $l = 1$ **to** L **do**

$\mathbf{h}^{(l)} \leftarrow \text{MessagePassing}(\mathbf{h}^{(l-1)}, \mathcal{G}, \Theta)$

end for

$\hat{u}(\mathbf{r}, t) \leftarrow \text{MLP}(\mathbf{h}^{(L)})$ // Fire intensity

$\mathcal{L}_{\text{koop}} \leftarrow \text{Eq. 13}$

$\mathcal{L}_{\text{PDE}} \leftarrow \text{Eq. 20}$

$\mathcal{L}_{\text{total}} += \text{Eq. 21}$

end for

$\theta, \phi, \psi, \Theta \leftarrow \text{Adam}(\nabla \mathcal{L}_{\text{total}})$

if $\tau \bmod 10 = 0$ **then**

Validate on held-out temporal window

end if

end for

return $g_\phi, h_\psi, \mathbf{K}_\theta, \Theta$




Figure 4: Detection system performance: precision, recall, F1-score, average response time and GOES-16 coverage.




Figure 5: Monthly evolution of wildfire hotspots in Ceará, comparing 2024 and 2025 (synthetic data based on real trends).




Figure 6: Hybrid Neural Koopman Operator and PI-GNN architecture. Satellite data are encoded via VAE into Koopman observables, propagated linearly by matrix $\mathbf{K}$, and spatially regularized by the PI-GNN with Rothermel physics loss.