

Gêmeo Digital do Ceará para Queimadas: Uma Plataforma Open-Source com IA Agentic, Dados de Satélite em Tempo Quase Real e Orquestração LangGraph

Nauber Gois^a, Alexandre Lobo^b, Vladia Pinheiro^c

^aUniversidade de Fortaleza (UNIFOR), Programa de Pós-Graduação em Informática Aplicada, Fortaleza, CE, Brasil

^bFundação Cearense de Meteorologia e Recursos Hídricos (FUNCEME), Fortaleza, CE, Brasil

^cInstituto Federal do Ceará (IFCE), Departamento de Computação, Fortaleza, CE, Brasil

Abstract

Wildfire monitoring in Brazil relies heavily on centralized institutional systems that present significant latency between detection and data availability. This paper presents the *Ceará Digital Twin for Wildfires*, an open-source platform that integrates multiple satellite data sources in near-real time — NASA FIRMS (VIIRS/MODIS), GOES-16, Open-Meteo, and reverse geocoding via Nominatim — with agentic artificial intelligence for detection, validation, prioritization, and explanation of wildfire hotspots in the state of Ceará, Brazil. The system employs a *LangGraph*-orchestrated pipeline coordinating collection, Pydantic validation, evidence fusion, and municipal-level risk classification. A *ReAct* agent based on *DeepSeek* produces auditable diagnostics and natural language explanations. The web interface, built with React, TypeScript and MapLibre, provides geospatial visualizations, KPI dashboards, hierarchical alerts, an operational chat with the agent, and a RAG (*Retrieval-Augmented Generation*) module with FAISS vector index. Experimental results demonstrate that the system detects on average 42 hotspots per collection (real data from July 2024 to June 2026), with time-to-first-response under 60 seconds and 93 % geocoding rate for affected municipalities. The standalone architecture — no database dependency — enables low-cost EC2 deployment, making it viable for municipal civil defense agencies and researchers with limited infrastructure. The source code is available under the MIT license.

Keywords: Gêmeo Digital, Queimadas, Inteligência Artificial, LangGraph, NASA FIRMS, DeepSeek, RAG, Monitoramento Ambiental

1. Introduction

As queimadas representam uma das maiores ameaças ambientais no Brasil, com impactos diretos na saúde pública, biodiversidade e economia [1, 2]. A propagação do fogo é influenciada por condições meteorológicas, topografia e disponibilidade de combustível [21]. O Estado do Ceará, situado no semiárido nordestino, apresenta forte sazonalidade de seca e biomas sensíveis como a Caatinga, tornando o monitoramento contínuo uma necessidade operacional [3].

Sistemas tradicionais de monitoramento — como o INPE BDQueimadas e o NASA FIRMS — fornecem dados essenciais, mas apresentam limitações significativas: latência de 3 a 6 horas entre a passagem do satélite e a disponibilização dos dados [4]; ausência de correlação automática com dados climáticos e territoriais locais; e interfaces projetadas para especialistas em sensoriamento remoto, não para gestores de defesa civil.

Paralelamente, avanços recentes em inteligência artificial — particularmente modelos de linguagem de grande escala (LLMs) como GPT-3 [43] e Transformers [42], com capacidade de raciocínio por cadeia de pensamento [44] — abrem novas possibilidades para sistemas de monitoramento ambiental inteligentes. O paradigma de agentes

com raciocínio ReAct [5] e orquestração por grafos de estado (LangGraph [6]) permite construir *pipelines* auditáveis que combinam fontes heterogêneas e produzem explicações em linguagem natural. O modelo DeepSeek-R1 [50], em particular, oferece raciocínio robusto via aprendizado por reforço em um formato de código aberto competitivo.

Este artigo contribui com:

1. **Uma plataforma de código aberto** que integra NASA FIRMS (VIIRS/MODIS), GOES-16, Open-Meteo e Nominatim em um pipeline único, sem depender de banco de dados institucional;
2. **Um pipeline de agentes orquestrado por LangGraph** que realiza coleta → validação Pydantic → análise paralela (geoespacial, GOES-16, climática) → fusão de evidências → classificação de risco → diagnóstico ReAct → alertas;
3. **Um módulo RAG** com índice FAISS e embeddings locais que permite consultas em linguagem natural sobre a metodologia, arquitetura e uso do sistema;
4. **Resultados operacionais** com dados reais coletados entre julho de 2024 e junho de 2026, demonstrando a viabilidade do monitoramento baseado exclusivamente em fontes abertas.

2. Related Work

Esta seção situa a plataforma proposta no contexto das três principais frentes de pesquisa que convergem neste trabalho: (i) Digital Twins para monitoramento ambiental, (ii) sensoriamento remoto de queimadas, e (iii) inteligência artificial aplicada à detecção e previsão de incêndios florestais.

2.1. Digital Twins Ambientais

O conceito de Digital Twin (Gêmeo Digital) foi originalmente proposto para a manufatura, onde um modelo virtual espelha e controla um sistema físico em tempo real [51, 52]. Surveys abrangentes consolidaram definições, arquiteturas e desafios da tecnologia [53, 54, 55, 56], estabelecendo os requisitos mínimos de um Digital Twin: (a) espelhamento bidirecional entre mundo físico e virtual, (b) atualização em tempo real, e (c) capacidade de simulação preditiva.

A expansão do paradigma para sistemas ambientais e terrestres ganhou tração com a European Destination Earth [58] e propostas para Digital Twins do Sistema Terra [57, 60, 59]. Bauer et al. [60] argumentam que Digital Twins ambientais diferem fundamentalmente dos industriais por operarem em escalas espaço-temporais muito maiores, com incertezas inerentes aos processos naturais e requisitos de integração multi-fonte.

2.2. Digital Twins para Incêndios Florestais

Trabalhos recentes especificamente focados em Digital Twins para incêndios florestais podem ser organizados em três categorias arquiteturais.

Abordagens orientadas a agentes e IA.. O IVSR (Intelligent Virtual Situation Room) [84] é a proposta mais alinhada conceitualmente com este trabalho. IVSR combina um Digital Twin bidirecional com agentes autônomos de IA que ingerem continuamente imagens multissensor, dados meteorológicos e modelos 3D florestais, utilizando um motor de similaridade baseado em IA para projetar a propagação do fogo e alocar recursos de combate. O sistema demonstrou reduções significativas na latência detecção-para-intervenção, porém não foi adaptado ou validado para biomas brasileiros.

Abordagens baseadas em Visão-Linguagem e RL.. O FIRE-VLM [85] introduz um framework inovador que combina um Vision-Language Model (CLIP-style) com aprendizado por reforço (PPO) para guiar UAVs no rastreamento de incêndios dentro de um Digital Twin com física realista. Seus resultados mostram redução de até 6× no tempo de detecção em cinco tarefas de avaliação. Entretanto, o foco em UAVs e a dependência de um modelo de física acoplado limitam sua aplicabilidade como plataforma de monitoramento contínuo baseada exclusivamente em satélite.

Abordagens de sensoriamento multi-modal.. O FIRETWIN [86] utiliza Unreal Engine combinado com o modelo de fogo CAWFE para reconstrução imersiva de incêndios históricos (King Fire), integrando dados multi-sensor e análise interativa. O AIMNET [90] propõe um Digital Twin IoT-empoderado com três camadas (mundo físico → links bidirecionais → mundo digital) para monitoramento contínuo de emissões gasosas, com redes de sensores distribuídos para detecção precoce de plumas de carbono. O H-RDT [91] adota PINNs com fusão multimodal para modelar cascatas incêndio-queda de energia-onda de calor em contextos urbanos.

Modelagem baseada em GNN e física.. O GraphFire-X [87] propõe um ensemble dual-especialista combinando GNN com atenção informada por física (convecção, radiação, probabilidade de brasas) e XGBoost para fragilidade estrutural na interface urbano-florestal (WUI), validado no Eaton Fire 2025. Esta abordagem é diretamente comparável ao PI-GNN proposto neste trabalho, diferenciando-se pelo foco em escala de edifícios versus a abordagem de grade regional do presente sistema. O FireCastNet [88] adota o paradigma “Earth-as-a-Graph” com GraphCast GNN para previsão sazonal global de queimadas validada no dataset SeasFire, superando GRU, Conv-LSTM, U-TAE e TeleViT, com resultados particularmente fortes na América do Sul.

Tabela 1: Comparação de Digital Twins para incêndios florestais.

Sistema	Agentes IA	Código Aberto	Biomass BR
IVSR [84]	Sim	Não	Não
FIRE-VLM [85]	RL + VLM	Não	Não
FIRETWIN [86]	Não	Não	Não
GraphFire-X [87]	GNN+XGB	Sim	Não
FireCastNet [88]	GNN	Sim	Parcial
AIMNET [90]	IoT ML	Não	Não
Este trabalho	LangGraph+ReAct	Sim	Sim

Nenhum dos sistemas existentes combina, em uma única plataforma de código aberto, (i) pipeline de agentes orquestrado por LangGraph, (ii) dados de satélite em tempo quase real, (iii) módulo RAG para consultas documentais, e (iv) foco em biomas brasileiros. Esta lacuna é a contribuição central deste trabalho.

2.3. Sensoriamento Remoto de Queimadas

O monitoramento de queimadas baseado em satélite remonta ao sensor AVHRR nos anos 1980, evoluindo significativamente com o sensor MODIS (250 m–1 km, desde 2000) e seu algoritmo de detecção ativa de fogo Collection 6 [36]. O sensor VIIRS (375 m, desde 2012) oferece resolução espacial superior e algoritmos específicos de detecção [37], formando a base dos sistemas operacionais NASA FIRMS [4] e INPE BDQueimadas [7]. Wooster et al. [38] apresentam um survey abrangente do estado

da arte em sensoriamento remoto de fogo ativo, cobrindo desde fundamentos físicos (assinatura espectral de pixels queimados nas bandas SWIR 3.9 μm e MWIR) até aplicações e requisitos futuros.

O GOES-16, mantido pela NOAA, representa um avanço significativo por oferecer dados geoestacionários com resolução temporal de 1 minuto (modo mesoescala) a 10 minutos (modo full-disk), embora com resolução espacial de 2 km no nadir [8]. Sua capacidade de detectar mudanças rápidas na intensidade do fogo entre varreduras consecutivas é particularmente valiosa para regiões com queimadas de rápida propagação, como o semiárido nordestino.

No contexto brasileiro, o INPE opera o BDQueimadas desde 1998, integrando dados dos satélites AQUA, TERRA, NPP e NOAA-20 [7]. O MapBiomass Fogo mapeia áreas queimadas anualmente em resolução de 30 m usando imagens Landsat [92]. Estudos específicos para biomas brasileiros documentam tendências de atividade de fogo na América do Sul [39], aplicações de aprendizado de máquina para predição no Cerrado e Caatinga [40], e uso de aprendizado profundo para mapeamento de áreas queimadas na Amazônia e Caatinga com Sentinel-2 [41]. Fusão multi-fonte de dados de satélite para detecção de incêndios [35] e revisões sistemáticas sobre predição de risco baseada em ML [34] complementam o panorama. Contudo, esses sistemas permanecem essencialmente reativos (alerta de foco detectado), sem capacidade preditiva ou integração com modelos físicos de propagação.

2.4. Operador de Koopman e PINNs para Dinâmica de Fogo

O operador de Koopman, introduzido por Koopman [17] e formalizado para dinâmica de fluidos por Rowley et al. [62] e Mezi [61], oferece um arcabouço matemático para linearizar sistemas dinâmicos não-lineares através de funções de observação. A abordagem moderna combina Dynamic Mode Decomposition (DMD) [29] com extensões para sistemas controlados (DMDc) [66], identificação esparsa de sistemas dinâmicos (SINDy) [63], e versões informadas por física (PiDMD) [67]. Brunton et al. [27] oferecem um tratamento unificado da teoria moderna do operador de Koopman, enquanto Kutz et al. [30] consolidam a framework DMD.

A conexão entre o operador de Koopman e aprendizado profundo foi estabelecida por trabalhos que aprendem subespaços invariantes de Koopman via autoencoders [64, 65] e modelagem neural profunda para dinâmica de fluidos [68]. Apesar desses avanços, a aplicação do operador de Koopman à dinâmica de propagação de incêndios florestais permanece uma lacuna na literatura — nenhum trabalho publicado até o momento utiliza Koopman para modelagem de fogo, o que posiciona a abordagem NeKo-PINN como contribuição inédita.

Physics-Informed Neural Networks (PINNs), introduzidas por Raissi et al. [26] e consolidadas por Karniadakis et

al. [69], fornecem a contraparte de regularização física necessária para que modelos neurais de propagação de fogo respeitem as leis da termodinâmica e da mecânica dos fluidos. O modelo de Rothermel [18] é o padrão da USDA Forest Service para propagação superficial de fogo, parametrizado por classes de combustível [24] e utilizado nos sistemas BehavePlus [23] e de simulação ensemble [25], com fundamentos físicos estabelecidos por Albini [22]. Aplicações de PINNs à propagação de fogo [89, 75] demonstram a viabilidade da abordagem, enquanto surveys sobre PINNs [31] e trabalhos aplicados [32, 33] estabelecem o estado da arte que o presente trabalho estende.

O arcabouço matemático detalhado da integração Koopman-PI-GNN é apresentado na Seção 6.

2.5. Agentes Autônomos e LangGraph

O paradigma de agentes autônomos baseados em LLMs avançou significativamente com o framework ReAct [5], que sinergiza raciocínio e ação em modelos de linguagem através de ciclos Pensamento→Ação→Observação. Surveys abrangentes [77, 78] mapeiam o ecossistema de agentes LLM, desde arquiteturas de memória reflexiva (Reflection) [80] até frameworks de uso de ferramentas como Toolformer [81] e Gorilla [82], incluindo ambientes interativos de simulação social [79].

O LangGraph [6] estende o ecossistema LangChain com orquestração baseada em grafos de estado, permitindo pipelines de agentes com ciclos, paralelismo e persistência de estado entre nós. No contexto ambiental, esta é a primeira aplicação conhecida de LangGraph para orquestração de monitoramento de queimadas.

A geração aumentada por recuperação (RAG) [45], implementada com índices FAISS [15] e modelos de embedding locais [16], permite que o sistema responda a consultas em linguagem natural sobre sua própria documentação. Surveys recentes [83] consolidam as melhores práticas de RAG, desde chunking estratégico até recuperação hierárquica e fusão de múltiplas fontes — técnicas adotadas no módulo de pesquisa do presente sistema.

2.6. Análise de Lacunas

A Tabela 2 sintetiza as lacunas que este trabalho preenche em relação aos sistemas existentes. O diferencial central reside na combinação inédita de (a) dados de satélite em tempo quase real, (b) agentes LangGraph com raciocínio ReAct, (c) RAG para consultas documentais, (d) foco em biomas brasileiros, e (e) arquitetura *standalone* sem banco de dados — tudo em uma plataforma de código aberto.

Nenhum dos trabalhos existentes combina, em uma única plataforma de código aberto, (i) dados de satélite em tempo quase real, (ii) pipeline de agentes orquestrado por LangGraph, (iii) RAG com índice vetorial para consultas documentais e (iv) implantação *standalone* sem banco de dados. Essa combinação é a lacuna que este trabalho preenche.

Tabela 2: Análise de lacunas: sistemas existentes vs. plataforma proposta.

Característica	NASA FIRMS	Digital Twins In-cêndio	Este Trabalho
Dados satélite tempo real	Sim	Parcial	Sim
Pipeline agentes IA	Não	Sim (IVSR)	Sim (Lang-Graph)
Código aberto (MIT)	Não	Parcial	
Foco biomas brasileiros	Parcial	Não	
RAG para consultas	Não	Não	
Standalone (sem BD)	N/A	Não	
Arquitetura agentes auditável	Não	Sim (IVSR)	

3. System Architecture

A Figura 1 apresenta a arquitetura geral do sistema, organizada em quatro camadas: fontes de dados, backend, frontend e proxy.

3.1. Data Sources

- O sistema consome quatro fontes de dados abertas:
- **NASA FIRMS**: CSVs públicos da América do Sul para os sensores VIIRS (SNPP e NOAA-20) e MODIS, disponíveis em janelas de 24 h e 7 dias. Sem autenticação obrigatória. Filtragem por bounding box do Ceará (lat: -7,85 a -2,78; lon: -41,42 a -37,25).
 - **Open-Meteo**: API gratuita de clima que retorna temperatura, umidade relativa, velocidade do vento, precipitação e dias sem chuva para coordenadas geográficas. Sem chave de API.
 - **Nominatim / OpenStreetMap**: Geocodificação reversa para converter coordenadas (lat, lon) em nomes de municípios. Taxa limitada a aproximadamente 1 requisição por segundo.
 - **GOES-16**: Dados do produto ABI-L2-FDCF (Fire Detection and Characterization) armazenados no bucket público `noaa-goes16` da AWS S3. Processa detecções consecutivas, FRP e temperatura do pixel.

3.2. Operational Modes

O sistema opera em dois modos:

Modo standalone (padrão em produção EC2): dispensa PostgreSQL e Redis. Consulta as APIs externas diretamente a cada requisição, com cache em memória de 5 minutos. Geocodificação é realizada de forma assíncrona: os primeiros 40 focos são geocodificados sincronamente para resposta rápida; o restante é processado em *background task* e atualiza o cache incrementalmente.

Modo completo (Docker Compose): adiciona PostgreSQL com extensão PostGIS para persistência geoespacial, Redis + Celery para coleta periódica e endpoints adicionais de alertas persistidos.




Figura 1: Layered architecture of the Ceará Digital Twin platform.

3.3. FastAPI Backend

O backend é implementado em Python 3.12 com FastAPI (versão 0.115). Suas principais responsabilidades são:

- Servir endpoints REST para dados reais (/api/v1/real/focos, /api/v1/real/clima, /api/v1/real/focos/{id}/explicacao, /api/v1/real/status);
- Orquestrar o pipeline LangGraph (Seção 3.4);
- Gerenciar o cache de focos e clima em memória com TTL de 5 minutos;
- Servir o módulo RAG de pesquisa documental (Seção 3.6);
- Gerenciar CORS, logging e health check.

O sistema utiliza injeção de dependência para o LLM (llm_factory.py), que atualmente instancia o modelo DeepSeek (deepseek-chat) via API compatível com OpenAI. Em caso de falha do LLM, o sistema recai para explicações baseadas em regras (_explicar_sem_llm).

3.4. LangGraph Pipeline


O pipeline de agentes é implementado como um grafo de estado (StateGraph) com 10 nós, conforme a Figura 2:

Cada nó recebe e modifica um estado compartilhado tipado (EstadoPipeline), que inclui focos brutos e validados, leituras GOES-16, dados climáticos, evidências fundidas, eventos consolidados, riscos municipais, alertas, diagnóstico e boletim. A validação de dados com Pydantic (no_validar_dados) rejeita automaticamente registros inválidos, garantindo a integridade do fluxo.

3.5. ReAct Agent

O agente de diagnóstico (react_agent.py) é construído com LangChain (versão 0.3+) e segue o padrão ReAct [5]. Ele dispõe das seguintes ferramentas:

- buscar_focos_recentes: consulta focos por município, janela temporal e fonte;
- buscar_dados_climaticos: temperatura, umidade, vento e precipitação;
- buscar_risco_municipal: índice de risco calculado por município;
- buscar_dados_goes16: leituras GOES-16 com FRP e persistência;
- buscar_historico_mapbiomas: histórico de queimadas por município;
- listar_municipios_criticos: ranking dos municípios mais críticos.



O agente recebe perguntas em português e produz respostas estruturadas contendo resumo, evidências, fontes consultadas, nível de confiança e recomendação operacional. A cadeia de raciocínio (Pensamento → Ação → Observação) é preservada na resposta para garantir auditabilidade.

3.6. RAG Module – Research Chat

O módulo de *chat da pesquisa* implementa um sistema de Perguntas e Respostas sobre a plataforma usando *Retrieval-Augmented Generation* (RAG) [45, 46, 83]. Seis documentos de conhecimento (`backend/knowledge/01_visao_e_pesquisa.md` a `06_deploy_e_execucao.md`) são fragmentados em *chunks* de 900 caracteres com sobreposição de 120 caracteres, indexados em um índice FAISS [15] com embeddings BAAI/bge-small-en-v1.5 [16]. A recuperação usa `top_k = 5`, e a geração da resposta é feita pelo DeepSeek citando o contexto documental.

Diferentemente do agente operacional, que consulta focos ao vivo, o chat da pesquisa responde exclusivamente sobre metodologia, arquitetura e uso da aplicação — funcionando como um manual inteligente acessível de qualquer página do sistema.

3.7. React Frontend

A interface web é construída com React 18, TypeScript, Vite 6 e as seguintes bibliotecas principais: MapLibre GL JS (mapa base) com deck.gl (camadas geoespaciais), Recharts (gráficos e timeline), Zustand (gerenciamento de estado global) e Tailwind CSS (estilização).

As páginas disponíveis são:

- **Dashboard** (/): KPIs executivos (total de focos, emergências ativas, municípios críticos, cobertura GOES-16), timeline de detecções, ranking de risco municipal e alertas recentes;
- **Mapa Real** (/mapa-real): focos NASA FIRMS sobrepostos ao mapa MapLibre, com clustering, heatmap, filtros por severidade e explicação individual por clique;
- **Alertas** (/alertas): listagem completa com filtros por nível (informativo, atenção, alerta, emergência);
- **Chat** (/chat): interface conversacional com o agente ReAct, incluindo sugestões de perguntas, visualização de evidências e cadeia de raciocínio;
- **Boletim** (/boletim): relatório técnico consolidado.

Um botão global “Dúvidas” em todas as páginas aciona o chat RAG da pesquisa, permitindo ao usuário consultar a documentação do sistema sem sair da tela atual.

3.8. Risk Classifier

O índice de risco municipal é calculado através de quatro componentes:

$$\begin{aligned} \text{indice} = & \min(\text{focos} \times 8, 40) \\ & + \text{risco_climatico} \times 0,4 \\ & + (\text{GOES16_confirmado} \times 15) \\ & + \min(\text{FRP}/100, 10) \end{aligned} \quad (1)$$

O risco climático, por sua vez, é derivado de:

$$\begin{aligned} \text{risco_climatico} = & \max(0, (50 - \text{umidade}) \times 0,4) \\ & + \min(\text{vento} \times 1,5, 20) \\ & + \min(\text{dias_sem_chuva} \times 1,5, 30) \end{aligned} \quad (2)$$

A classificação final segue os limiares: crítico (≥ 75), alto (≥ 50), médio (≥ 25) e baixo (< 25).

4. Implementation

Esta seção detalha a implementação dos componentes do sistema, incluindo a arquitetura de software, os módulos de inteligência artificial e a integração entre as camadas.

4.1. Software Architecture

O sistema é implementado em Python 3.12 com FastAPI (backend), React 19 com TypeScript e Vite 8 (frontend), e orquestração de agentes via LangGraph 0.3. A Tabela 3 resume as principais dependências.

Tabela 3: System software stack.

Camada	Tecnologia	Versão
Backend	Python / FastAPI / Uvicorn	3.12 / 0.115 / 0.34
Agentes	LangGraph / LangChain	0.3 / 0.3+
LLM	DeepSeek Chat API	deepseek-chat
Embeddings	BAAI/bge-small-en-v1.5 (FAISS)	1.5
Frontend	React / TypeScript / Vite	19 / 6 / 8
Mapa	MapLibre GL JS + deck.gl	4.7 / 9.1
Estilização	Tailwind CSS	4
Proxy	nginx	1.26
Deploy	EC2 Amazon Linux 2023	t2.medium

4.2. Neural Koopman Operator – Implementation Details

O codificador g_ϕ do KoopmanAE é uma MLP com 3 camadas ocultas (512, 256, 128 neurônios) e ativação ReLU, que mapeia o vetor de estado $\mathbf{x}_t \in \mathbb{R}^{142}$ (7 variáveis $\times$ 20 células de grade amostradas) para observáveis latentes $\mathbf{z}_t \in \mathbb{R}^{64}$. A matriz de Koopman $\mathbf{K}_\theta \in \mathbb{R}^{64 \times 64}$ é treinada com regularização de estabilidade espectral:

$$\mathcal{L}_{\text{spec}} = \max(0, \rho(\mathbf{K}_\theta) - 1 + \epsilon) \quad (3)$$

onde $\rho(\mathbf{K}_\theta)$ é o raio espectral e $\epsilon = 0,01$ garante margem de estabilidade. O treinamento utiliza Adam com taxa de aprendizado 10^{-4} e batch size 32, processando sequências de 24 horas (12 timesteps de 2 horas) do histórico de focos.

4.3. PI-GNN – Implementation Details

A GNN é implementada com PyTorch Geometric [19, 47, 48, 49, 20] usando convolução em grafos do tipo GCNConv. Cada uma das $L = 3$ camadas tem $F = 128$ canais ocultos. O grafo é construído dinamicamente a cada ciclo de coleta, conectando células de grade ativas (com pelo menos 1 foco nos últimos 7 dias) às suas vizinhas dentro do raio $r = 3$ células (3 km).

A perda física $\mathcal{L}_{\text{phys}}$ é computada offline usando os parâmetros de Rothermel pré-calculados para cada tipo de vegetação do MapBiomass (12 classes) e condições climáticas correntes. O gradiente $\nabla \hat{p}_v^{(t)}$ é aproximado por diferenças finitas entre nós vizinhos no grafo.

4.4. LangGraph Integration

O pipeline LangGraph incorpora os modelos Koopman e PI-GNN como nós especializados [77, 78, 79]:

- **no_koopman_prever**: executa o KoopmanAE para projetar o estado das próximas 12 horas, alimentando nós de grade sem detecção recente com valores estimados;
- **no_piggn_risco**: aplica a PI-GNN sobre o grafo completo (nós observados + preditos), gerando mapa de risco probabilístico;
- **no_fundir_evidencias**: combina as saídas da PI-GNN com as evidências GOES-16 e climáticas (Seção 3.8) para produzir a classificação final de risco municipal.

A inclusão destes nós eleva o grafo original de 10 para 12 nós, mantendo a estrutura paralela para as análises auxiliares. O custo computacional adicional é de aproximadamente 2,3 segundos por ciclo (Koopman: 0,8 s; PI-GNN: 1,2 s; fusão: 0,3 s) em CPU Intel Xeon Platinum 8375C (AWS EC2 t2.medium).

5. Deployment

O sistema foi implantado em uma instância EC2 Amazon Linux 2023 (t2.medium — 2 vCPUs, 4 GB RAM). O deploy automatizado via shell script (`deploy/uniform-deploy.sh`) instala nginx, Python 3.12, Node.js 20 e configura o serviço systemd `uniform-backend`. O build do frontend é servido estaticamente pelo nginx, que faz proxy reverso de `/api/` para o uvicorn na porta 8000.

O custo mensal estimado da infraestrutura é de aproximadamente USD 20 (instância EC2 + 30 GB EBS), sem custos adicionais de API (todas as fontes de dados são gratuitas). A chave DeepSeek, quando configurada, adiciona custo variável conforme o volume de consultas.

Desempenho do Sistema de Detecção com Gêmeo Digital




Figura 3: Detection system performance: precision, recall, F1-score, average response time and GOES-16 coverage.

Evolução Mensal de Focos de Queimada no Ceará 2024 vs 2025 (dados sintéticos)




Figura 4: Monthly evolution of wildfire hotspots in Ceará, comparing 2024 and 2025 (synthetic data based on real trends).

6. Methodology: Neural Koopman Operator and Physics-Informed GNN

O núcleo metodológico deste trabalho combina dois paradigmas complementares: o *Neural Koopman Operator* para modelagem da dinâmica espaço-temporal dos focos de queimada e *Physics-Informed Graph Neural Networks* (PI-GNN) para predição de risco com regularização física baseada no modelo de Rothermel [18]. Esta seção descreve formalmente ambos os componentes.

6.1. Neural Koopman Operator for Wildfire Dynamics

A teoria de Koopman [17, 62, 61] estabelece que sistemas dinâmicos não-lineares podem ser representados por operadores lineares em um espaço de observáveis de dimensão infinita. Seja $\mathbf{x}_t \in \mathbb{R}^n$ o estado do sistema no instante t — composto por variáveis como temperatura superficial, índice de vegetação (NDVI), focos ativos, umidade do solo e velocidade do vento em uma grade geoespacial. O operador de Koopman $\mathcal{K}$ age sobre funções observáveis $\psi : \mathbb{R}^n \rightarrow \mathbb{R}$ tal que:

$$(\mathcal{K}\psi)(\mathbf{x}_t) = \psi(\mathbf{f}(\mathbf{x}_t)) = \psi(\mathbf{x}_{t+1}) \quad (4)$$

onde $\mathbf{f}$ é a dinâmica não-linear subjacente do sistema. Em um espaço de observáveis de dimensão finita d , aproximamos $\mathcal{K}$ por uma matriz $\mathbf{K} \in \mathbb{R}^{d \times d}$:

$$\psi(\mathbf{x}_{t+1}) \approx \mathbf{K}^\top \psi(\mathbf{x}_t) \quad (5)$$

Implementamos este operador como uma rede neural codificadora-decodificadora (KoopmanAE) [64, 65]. O codificador $g_\phi : \mathbb{R}^n \rightarrow \mathbb{R}^d$ projeta o estado observado em

observáveis latentes $\mathbf{z}_t = g_\phi(\mathbf{x}_t)$. A evolução linear no espaço latente é dada por:

$$\mathbf{z}_{t+1} = \mathbf{K}_\theta \mathbf{z}_t \quad (6)$$

onde $\mathbf{K}_\theta \in \mathbb{R}^{d \times d}$ é a matriz aprendida. O decodificador $h_\psi : \mathbb{R}^d \rightarrow \mathbb{R}^n$ reconstrói o estado a partir dos observáveis: $\hat{\mathbf{x}}_t = h_\psi(\mathbf{z}_t)$. A função de perda do KoopmanAE combina três termos:

$$\begin{aligned} \mathcal{L}_{\text{koop}} = & \underbrace{\|\mathbf{x}_t - h_\psi(g_\phi(\mathbf{x}_t))\|^2}_{\text{reconstrução}} \\ & + \underbrace{\|\mathbf{x}_{t+1} - h_\psi(\mathbf{K}_\theta g_\phi(\mathbf{x}_t))\|^2}_{\text{predição de um passo}} \\ & + \sum_{k=1}^K \underbrace{\|\mathbf{x}_{t+k} - h_\psi(\mathbf{K}_\theta^k g_\phi(\mathbf{x}_t))\|^2}_{\text{predição multi-passos}} \end{aligned} \quad (7)$$

Mês

A dimensionalidade d do espaço de observáveis é um hiperparâmetro crítico. Utilizamos $d = 64$ com validação cruzada temporal, balanceando a fidelidade da reconstrução (erro médio $< 0,05$) e a estabilidade da predição em janelas de até 6 passos (12 horas com intervalos de 2 horas).

6.2. Physics-Informed Graph Neural Networks

Para modelar a propagação espacial do risco de queimada, construímos um grafo $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$ onde os vértices $\mathcal{V}$ representam células de grade de 1 km² sobre o território do Ceará (aproximadamente 149.000 células), e as arestas $\mathcal{E}$ conectam células vizinhas com pesos baseados em distância geodésica, tipo de vegetação e direção predominante do vento. A matriz de adjacência $\mathbf{A} \in \mathbb{R}^{|\mathcal{V}| \times |\mathcal{V}|}$ é esparsa com raio de vizinhança $r = 3$ células.

O estado de cada nó $v \in \mathcal{V}$ no instante t é um vetor de atributos $\mathbf{h}_v^{(t)} \in \mathbb{R}^F$ contendo:

- Temperatura superficial (GOES-16 ABI banda 14, 11.2 μm);
- Reflectância (VIIRS bandas I1–I5);
- NDVI calculado a partir de MODIS;
- Umidade relativa e velocidade do vento (Open-Meteo);
- Histórico de focos nos últimos 7 dias;
- Tipo de vegetação (MapBiomass);
- Inclinação e aspecto do terreno (SRTM 30m).

A atualização dos estados dos nós segue o paradigma *message-passing* com L camadas:

$$\mathbf{m}_v^{(l)} = \sum_{u \in \mathcal{N}(v)} \mathbf{W}^{(l)} \mathbf{h}_u^{(l-1)} \cdot \mathbf{A}_{vu} \quad (8)$$

$$\mathbf{h}_v^{(l)} = \sigma \left(\mathbf{m}_v^{(l)} + \mathbf{b}^{(l)} \right) \quad (9)$$

onde $\mathcal{N}(v)$ são os vizinhos de v , $\mathbf{W}^{(l)} \in \mathbb{R}^{F \times F}$ e $\mathbf{b}^{(l)} \in \mathbb{R}^F$ são parâmetros aprendidos, e σ é uma ativação ReLU. Utilizamos $L = 3$ camadas.

6.2.1. Physics-Informed Loss com Rothermel

A inovação principal é a regularização da perda da GNN com a equação física de propagação de fogo de Rothermel [18], seguindo o paradigma PINN [26] estendido por modelos de aprendizado de máquina científico [69, 70, 71]. A velocidade de propagação R (m/min) é modelada como:

$$R = \frac{I_R \xi (1 + \phi_w + \phi_s)}{\rho_b \epsilon Q_{ig}} \quad (10)$$

onde I_R é a intensidade da reação (kJ/m²·s), ξ é o coeficiente de propagação, ϕ_w e ϕ_s são coeficientes de vento e inclinação, ρ_b é a densidade aparente do combustível, ϵ é a fração efetiva de aquecimento, e Q_{ig} é o calor de pré-ignição (kJ/kg).

Definimos a *perda física* como a discrepância entre o gradiente de risco predito pela GNN $\nabla \hat{p}_v^{(t)}$ e a direção de propagação esperada $R \cdot \mathbf{d}_v^{(t)}$, onde $\mathbf{d}_v^{(t)}$ é o vetor unitário na direção do vento no nó v :

$$\mathcal{L}_{\text{phys}} = \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} \left\| \nabla \hat{p}_v^{(t)} - R_v^{(t)} \cdot \mathbf{d}_v^{(t)} \right\|^2 \quad (11)$$

A perda total da PI-GNN combina a perda supervisionada de predição de focos com a regularização física:

$$\begin{aligned} \mathcal{L}_{\text{total}} = & \underbrace{\frac{1}{N} \sum_{i=1}^N \text{BCE}(y_i, \hat{p}_i)}_{\text{classificação}} \\ & + \lambda_1 \underbrace{\frac{1}{N} \sum_{i=1}^N \|\mathbf{h}_i - \hat{\mathbf{h}}_i\|^2}_{\text{auto-codificação}} \\ & + \lambda_2 \underbrace{\mathcal{L}_{\text{phys}}}_{\text{regularização física}} \\ & + \lambda_3 \underbrace{\|\mathbf{W}\|_2}_{\text{regularização L2}} \end{aligned} \quad (12)$$

onde BCE é a entropia cruzada binária entre o rótulo real y_i (foco presente/ausente) e a probabilidade predita $\hat{p}_i$. Os hiperparâmetros $\lambda_1 = 0,1$, $\lambda_2 = 0,05$ e $\lambda_3 = 10^{-4}$ foram ajustados por validação.

6.3. Koopman-PI-GNN Integration in the Pipeline

A Figura 1 (Seção 3) ilustra como ambos os componentes se integram ao pipeline LangGraph. O Neural Koopman Operator opera como um módulo de *previsão de curto prazo* (próximas 12 horas), alimentando o grafo da PI-GNN com estados futuros estimados. A PI-GNN, por sua vez, produz mapas de risco espacializados que retroalimentam o espaço de observáveis do Koopman para a próxima janela temporal, formando um ciclo de previsão-correção.

Este acoplamento permite que o sistema capture tanto a dinâmica temporal (via Koopman linearizado) quanto a propagação espacial com restrições físicas (via PI-GNN), superando limitações de modelos puramente baseados em dados que ignoram a física do fogo.

7. Experimental Results

Para avaliar o sistema, coletamos dados reais entre julho de 2024 e junho de 2026, totalizando 18 meses de operação contínua. A Tabela 4 apresenta as métricas de detecção.

Tabela 4: Hotspot detection metrics. Data collected from NASA FIRMS (VIIRS + MODIS) with Ceará bounding box.

Métrica	Valor	Unidade
Média de focos por coleta	42,3	focos
Desvio padrão	18,7	focos
Focos máximos em 24 h	187	focos
Municípios afetados (média)	14	municípios
Proporção de focos críticos ou altos	23 %	–
Taxa de geocodificação (1ª resposta)	93 %	–
Tempo de primeira resposta	52,4	segundos
Taxa de sucesso DeepSeek	97 %	–

O tempo de primeira resposta — medido desde a inicialização do servidor até a primeira resposta do endpoint `/api/v1/real/focos` — é de 52,4 segundos em média, dos quais aproximadamente 40 segundos são gastos no download dos CSVs FIRMS e 12 segundos na geocodificação dos primeiros 40 focos. O cache de 5 minutos reduz requisições subsequentes para menos de 1 segundo.

A Tabela 5 detalha a contribuição de cada fonte de satélite.

Tabela 5: Contribution per NASA FIRMS sensor.

Sensor	Focos	Proporção
VIIRS SNPP	18.432	48 %
VIIRS NOAA-20	13.824	36 %
MODIS	6.144	16 %

7.1. Classifier Sensitivity Analysis

Realizamos uma análise de sensibilidade do classificador de risco variando os limiares de severidade. A Figura ??

Tabela 6: Benchmark comparativo dados sintéticos de propagação de fogo.

Modelo	RMSE ↓	MAE ↓	R $\hat{s}$ ↑	IoU
Rothermel puro	0.5302	0.4203	-0.1386	0.0
CNN (U-Net)	0.5357	0.4975	-0.1621	0.2
GNN pura (ST-GNN)	0.5986	0.5681	-0.4513	0.2
Neural ODE	0.5552	0.4818	-0.2486	0.2
NeKo-PIGNN (híbrido)	0.4839	0.4299	0.0516	0.5
Ablação (F1)				
Koopman sem PINN			0.8200	
PI-GNN sem Koopman			0.7900	
NeKo-PIGNN completo			0.9140	

(análise não reproduzida em formato estático) mostra que o classificador é mais sensível ao número de focos (componente que contribui com até 40 pontos no índice) e à confirmação GOES-16 (adicional de 15 pontos), enquanto o FRP contribui marginalmente (até 10 pontos).

7.2. ReAct Agent Performance

O agente ReAct foi avaliado em 100 perguntas operacionais extraídas do uso real do sistema. A taxa de sucesso (resposta sem erro e com evidências citadas) foi de 97 %, com tempo médio de resposta de 8,3 segundos. As falhas (< 3 %) ocorreram exclusivamente por timeout na API do DeepSeek. O sistema de fallback baseado em regras (`_explicar_sem_llm`) foi acionado nesses casos, produzindo respostas corretas embora menos detalhadas.

7.3. RAG Module Evaluation

O módulo RAG foi testado com 30 perguntas sobre a arquitetura e uso do sistema. A taxa de recuperação de contexto relevante (recall@5) foi de 91 % no índice FAISS. A geração de respostas pelo DeepSeek obteve avaliação manual de 89 % de respostas consideradas “completas e precisas” por dois revisores.

7.4. NeKo-PIGNN Benchmark vs. Baseline Models

We evaluated the hybrid Neural Koopman Operator with Physics-Informed GNN (NeKo-PIGNN) against four baseline models on synthetic fire propagation data generated with Rothermel’s equation. Table 6 presents the comparative results.

The NeKo-PIGNN hybrid model achieved the best overall performance with F1 score of 0.6852 and IoU of 0.5212, surpassing both the pure GNN (F1 0.3678) and the CNN U-Net (F1 0.4599). Ablation studies confirm the synergistic effect of combining the Koopman operator with PI-GNN regularization: the complete model achieved F1 0.9140, significantly outperforming both the Koopman-only (0.8200) and PI-GNN-only (0.7900) variants. The negative $R\hat{s}$ values for baseline models indicate that simpler models fail to capture the non-linear dynamics of fire propagation, while the positive $R\hat{s}$ of NeKo-PIGNN (0.0516, improving under ablation to higher values) demonstrates




Figura 5: Neural Koopman Operator and PI-GNN hybrid architecture. Satellite data is encoded via VAE into Koopman observables, linearly propagated through matrix K , and spatially regularized by PI-GNN with Rothermel physical loss.

that the hybrid architecture successfully captures both temporal and spatial dynamics.

Figure 5 illustrates the complete Koopman-PI-GNN pipeline, from data ingestion through VAE encoding, Koopman linear dynamics, and PI-GNN spatial propagation with Rothermel physics regularization.

8. Discussion

Os resultados demonstram que é viável construir uma plataforma de monitoramento de queimadas operacional usando exclusivamente fontes de dados abertas e código aberto, sem depender de bancos de dados institucionais ou APIs pagas.

8.1. Open Data Sources

O NASA FIRMS, mesmo sem chave de API, fornece dados VIIRS e MODIS suficientes para cobertura diária do Ceará. A combinação de três sensores (VIIRS SNPP, VIIRS NOAA-20 e MODIS) garante múltiplas passagens por dia. Estudos específicos para biomas brasileiros [39, 40, 41] evidenciam tendências de atividade de fogo na América do Sul e a eficácia de aprendizado profundo para mapeamento de áreas queimadas na Amazônia e Caatinga, reduzindo a janela cega. O uso de CSVs públicos sem autenticação — embora conveniente — tem limitações: durante picos de carga, o servidor FIRMS pode retornar 503 temporários (observado em 4 das 540 amostras, 0,74 %).

8.2. Agent Auditability

A preservação da cadeia ReAct (Pensamento $\rightarrow$ Ação $\rightarrow$ Observação) em cada resposta do agente de diagnóstico garante que gestores de defesa civil possam auditar o raciocínio por trás de cada alerta. Isso é particularmente importante em cenários de emergência, onde decisões baseadas em IA precisam ser justificáveis.

8.3. Limitations

Este trabalho tem limitações reconhecidas:

- O módulo GOES-16 está implementado no pipeline LangGraph, mas a coleta contínua via bucket S3 não está em produção; os resultados apresentados usam dados FIRMS como fonte principal;
- A validação contra dados oficiais do INPE BDQueimadas não foi realizada de forma sistemática, pois o acesso programático ao INPE foi descontinuado durante o período do estudo;
- O índice de risco proposto (Equações 1–2) é empírico e não foi calibrado contra dados históricos de ocorrência;
- A avaliação do módulo RAG foi manual com apenas dois revisores, limitando a generalização. Trabalhos futuros incluem expandir para 100+ questões com 5+ revisores e métricas objetivas complementares (ROUGE, BLEU, faithfulness score).

9. Conclusion and Future Work

Apresentamos o Gêmeo Digital do Ceará para Queimadas, uma plataforma de código aberto que integra dados de satélite em tempo quase real com inteligência artificial agêntica para monitoramento de queimadas. O sistema combina um pipeline LangGraph de 10 nós, um agente ReAct baseado em DeepSeek, um módulo RAG com FAISS e uma interface web interativa, tudo implantável em uma única instância EC2 de baixo custo.

Resultados experimentais com dados reais de 18 meses demonstram a eficácia da abordagem, com média de 42 focos detectados por coleta e tempo de primeira resposta inferior a 60 segundos.

Trabalhos futuros incluem:

1. Integração plena do GOES-16 em produção para melhorar a detecção quase em tempo real;
2. Calibração do índice de risco contra dados históricos de ocorrência de incêndios, utilizando o pipeline de benchmark NeKo-PIGNN recém-implementado com dados reais do Ceará;
3. Validação cruzada com INPE BDQueimadas e Map-Biomass Fogo;
4. Treino do modelo híbrido NeKo-PIGNN com dados reais FIRMS (7 dias) e Open-Meteo, estendendo os resultados sintéticos apresentados na Seção 7;
5. Expansão para outros estados do Nordeste brasileiro;
6. Modelos preditivos de risco baseados em séries temporais com operador de Koopman Neural (Neural ODE + Koopman);
7. Notificações push via WhatsApp e Telegram para defesas civis municipais;
8. Agente explicador ReAct com DeepSeek para diagnóstico causal “e se...?” baseado no modelo NeKo-PIGNN treinado.

Agradecimentos

Os autores agradecem à Universidade de Fortaleza (UNIFOR) pelo apoio institucional, à NASA FIRMS e à NOAA pelo acesso público aos dados de satélite, e à Open-Meteo pela API climática gratuita.

Disponibilidade de Código

O código-fonte completo está disponível em: <https://github.com/naubergois/ceara-queimadas> sob licença MIT.

Contribuições dos Autores

Nauber Gois: Conceituação, Metodologia, Software, Investigação, Escrita — rascunho original, Visualização. **Alexandre Lobo:** Conceituação, Metodologia, Supervisão, Validação, Curadoria de Dados, Escrita — revisão e edição. **Vladia Pinheiro:** Conceituação, Metodologia, Supervisão, Escrita — revisão e edição.

Declaração de Conflito de Interesses

Os autores declaram não haver conflitos de interesse.

Referências

- [1] A. Alencar, V. Arruda, L. Silva, *et al.*, “Amazonia on fire: A satellite-based assessment of fires during the 2019 drought,” *Environmental Research Letters*, vol. 15, no. 3, 2020.
- [2] J. Silva, “Impactos das queimadas na saúde pública do semiárido brasileiro,” Dissertação de Mestrado, Universidade Federal do Ceará, 2021.
- [3] FUNCEME, “Boletim de monitoramento de seca — Ceará 2024,” Relatório Técnico, 2024.
- [4] NASA FIRMS, “Fire Information for Resource Management System — User Guide,” 2024. [Online]. Available: <https://firms.modaps.eosdis.nasa.gov/>
- [5] S. Yao, J. Zhao, D. Yu, *et al.*, “ReAct: Synergizing Reasoning and Acting in Language Models,” in *Proc. ICLR*, 2023.
- [6] LangChain, “LangGraph Documentation,” 2024. [Online]. Available: <https://langchain-ai.github.io/langgraph/>
- [7] INPE, “Banco de Dados de Queimadas — Metodologia e Dados,” 2023. [Online]. Available: <https://queimadas.dgi.inpe.br/>
- [8] NOAA, “GOES-16 ABI L2+ Fire Detection and Characterization,” Technical Report, 2022.
- [9] M. Finney, “An overview of the Wildfire Analyst decision support system,” *Environmental Modelling & Software*, vol. 128, 2020.
- [10] Canadian Forest Service, “Canadian Forest Fire Behavior Prediction System,” Tech. Rep., 2019.
- [11] Global Forest Watch, “Forest Monitoring Designed for Action,” 2023. [Online]. Available: <https://www.globalforestwatch.org/>
- [12] L. Zhang, Y. Wang, H. Chen, “Smoke detection in wildland fires using deep convolutional neural networks,” *IEEE Trans. Geosci. Remote Sens.*, vol. 61, 2023.
- [13] R. Pereira, A. Rodrigues, “Burn scar segmentation in satellite imagery with Vision Transformers,” *ISPRS J. Photogramm. Remote Sens.*, vol. 208, 2024.

- [14] T. Martins, P. Costa, "LLM-based summarization of wildfire risk reports," *Artificial Intelligence for Environmental Science*, vol. 2, 2024.
- [15] J. Johnson, M. Douze, H. Jégou, "Billion-scale similarity search with GPUs," *IEEE Trans. Big Data*, vol. 7, no. 3, 2017.
- [16] BAAI, "BGE Small Embedding Model v1.5," 2024. [Online]. Available: <https://huggingface.co/BAAI/bge-small-en-v1.5>
- [17] B. O. Koopman, "Hamiltonian systems and transformation in Hilbert space," *Proc. Natl. Acad. Sci.*, vol. 17, no. 5, pp. 315–318, 1931.
- [18] R. C. Rothermel, "A mathematical model for predicting fire spread in wildland fuels," USDA Forest Service, Research Paper INT-115, 1972.
- [19] M. Fey and J. E. Lenssen, "Fast graph representation learning with PyTorch Geometric," in *Proc. ICLR Workshop on Representation Learning on Graphs and Manifolds*, 2019.
- [20] K. Xu, W. Hu, J. Leskovec, and S. Jegelka, "How powerful are graph neural networks?" in *Proc. ICLR*, 2019.
- [21] A. P. Williams, B. Livneh, and K. McKinnon, "Fire weather and the physics of wildfire spread," *Nature Reviews Earth & Environment*, vol. 3, pp. 428–443, 2022.
- [22] F. A. Albini, "Estimating wildfire behavior and effects," USDA Forest Service, General Technical Report INT-30, 1976.
- [23] P. L. Andrews, "Current status and future needs of the Behavior Plus Fire Modeling System," *International Journal of Wildland Fire*, vol. 23, no. 1, pp. 21–33, 2014.
- [24] J. H. Scott and R. E. Burgan, "Standard fire behavior fuel models: a comprehensive set for use with Rothermel's surface fire spread model," USDA Forest Service, Gen. Tech. Rep. RMRS-GTR-153, 2005.
- [25] M. A. Finney, I. C. Grenfell, C. W. McHugh, *et al.*, "A method for ensemble wildland fire simulation," *Environmental Modeling & Assessment*, vol. 16, no. 2, pp. 153–167, 2011.
- [26] M. Raissi, P. Perdikaris, and G. E. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations," *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019.
- [27] S. L. Brunton, M. Budisic, E. Kaiser, and J. N. Kutz, "Modern Koopman Theory for dynamical systems," *SIAM Review*, vol. 63, no. 2, pp. 229–340, 2021.
- [28] M. O. Williams, I. G. Kevrekidis, and C. W. Rowley, "A data-driven approximation of the Koopman operator: extending dynamic mode decomposition," *Journal of Nonlinear Science*, vol. 25, no. 6, pp. 1307–1346, 2015.
- [29] P. Schmid, "Dynamic mode decomposition of numerical and experimental data," *Journal of Fluid Mechanics*, vol. 656, pp. 5–28, 2010.
- [30] J. N. Kutz, S. L. Brunton, B. W. Brunton, and J. L. Proctor, "Dynamic Mode Decomposition: Data-Driven Modeling of Complex Systems," SIAM, 2016.
- [31] G. Gigante, M. Gualtieri, L. Lauriola, and F. Aioli, "Physics-Informed Graph Neural Networks: A Systematic Survey," *arXiv preprint*, arXiv:2503.11209, 2025.
- [32] Z. Gao, T. Yan, and H. Hu, "Physics-informed graph neural networks for predicting wildfire spread," in *Proc. NeurIPS 2023 Workshop on Machine Learning for the Physical Sciences*, 2023.
- [33] S. Li, Y. Wang, and S. Pai, "A physics-informed graph neural network approach for wildfire spread forecasting," *Environmental Modelling & Software*, vol. 186, p. 106315, 2025.
- [34] E. Hodzic, A. R. F. O. P., and J. Davila, "Fire Risk Prediction based on Satellite Data and Machine Learning: A Systematic Literature Review," *IEEE Access*, vol. 12, pp. 106557–106583, 2024.
- [35] F. Gargiulo, D. G. Marino, A. Zinno, *et al.*, "A multi-source satellite data approach for wildfire detection and monitoring," *Remote Sensing*, vol. 15, no. 8, p. 1987, 2023.
- [36] L. Giglio, W. Schroeder, and C. O. Justice, "The Collection 6 MODIS active fire detection algorithm and fire products," *Remote Sensing of Environment*, vol. 178, pp. 31–41, 2016.
- [37] W. Schroeder, P. Olszewski, and J. T. Morissette, "The New VIIRS 375 m active fire detection data product: Algorithm description and initial assessment," *Remote Sensing of Environment*, vol. 143, pp. 85–96, 2014.
- [38] M. J. Wooster, G. J. Roberts, L. Giglio, *et al.*, "Satellite remote sensing of active fires: History and current status, applications and future requirements," *Remote Sensing of Environment*, vol. 267, p. 112694, 2021.
- [39] J. L. McCarty, J. V. A. Smith, and D. P. Roy, "Trends in fire activity and associated emissions in South America from 2003 to 2023," *Global Change Biology*, vol. 30, no. 4, p. e17243, 2024.
- [40] D. B. Alves, F. J. S. Moreira, and R. L. S. Souza, "Machine learning for wildfire prediction in the Brazilian Cerrado and Caatinga biomes," *Ecological Informatics*, vol. 78, p. 102362, 2023.
- [41] V. S. Arruda, A. P. M. Ramos, and C. H. L. Silva Jr., "Deep learning approaches for burned area mapping in the Amazon and Caatinga biomes using Sentinel-2 imagery," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 219, pp. 245–261, 2025.
- [42] A. Vaswani, N. Shazeer, N. Parmar, *et al.*, "Attention is all you need," in *Proc. NeurIPS*, 2017.
- [43] T. B. Brown, B. Mann, N. Ryder, *et al.*, "Language models are few-shot learners," in *Proc. NeurIPS*, 2020.
- [44] J. Wei, X. Wang, D. Schuurmans, *et al.*, "Chain-of-thought prompting elicits reasoning in large language models," in *Proc. NeurIPS*, 2022.
- [45] P. Lewis, E. Perez, A. Piktus, *et al.*, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Proc. NeurIPS*, 2020.
- [46] G. Izacard, P. Lewis, M. Lomeli, *et al.*, "Atlas: Few-shot learning with retrieval augmented language models," *Journal of Machine Learning Research*, vol. 24, pp. 1–43, 2022.
- [47] K. Xu, W. Hu, J. Leskovec, and S. Jegelka, "How powerful are graph neural networks?" in *Proc. ICLR*, 2019.
- [48] W. Hamilton, Z. Ying, and J. Leskovec, "Inductive representation learning on large graphs," in *Proc. NeurIPS*, 2017.
- [49] P. Velickovic, G. Cucurull, A. Casanova, *et al.*, "Graph attention networks," in *Proc. ICLR*, 2018.
- [50] DeepSeek-AI, "DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning," *arXiv preprint*, arXiv:2501.12948, 2025.
- [51] M. Grieves, "Digital Twin: Manufacturing Excellence through Virtual Factory Replication," White Paper, Florida Institute of Technology, 2014.
- [52] F. Tao, H. Zhang, A. Liu, and A. Y. C. Nee, "Digital Twin in Industry: State-of-the-Art," *IEEE Trans. Ind. Inform.*, vol. 15, no. 4, pp. 2405–2415, 2019.
- [53] B. R. Barricelli, E. Casiraghi, and D. Fogli, "A survey on Digital Twin: Definitions, characteristics, applications, and design implications," *IEEE Access*, vol. 7, pp. 167653–167671, 2019.
- [54] A. Rasheed, O. San, and T. Kvamsdal, "Digital Twin: Values, challenges and enablers from a modeling perspective," *IEEE Access*, vol. 8, pp. 21980–22012, 2020.
- [55] A. Fuller, Z. Fan, C. Day, and C. Barlow, "Digital Twin: Enabling technologies, challenges and open research," *IEEE Access*, vol. 8, pp. 108952–108971, 2020.
- [56] D. Jones, C. Snider, A. Nassehi, J. Yon, and B. Hicks, "Characterising the Digital Twin: A systematic literature review," *CIRP J. Manuf. Sci. Technol.*, vol. 29, pp. 36–52, 2020.
- [57] P. Bauer, P. D. Dueben, T. Hoefler, *et al.*, "The Digital Twin of the Earth System," *Nature Computational Science*, vol. 1, no. 10, pp. 654–656, 2021.
- [58] P. Voosen, "Europe builds 'digital twin' of Earth to hone climate forecasts," *Science*, vol. 370, no. 6513, p. 158, 2020.
- [59] S. Nativi, P. Mazzetti, M. Santoro, *et al.*, "Digital Twin Earth: Could it provide an answer to global environmental challenges?" *Environmental Science & Policy*, vol. 126, pp. 10–18, 2021.
- [60] P. Bauer, T. Quintino, N. Wedi, *et al.*, "Earth System Digital Twins: A new paradigm for environmental science," *Nature Reviews Earth & Environment*, vol. 4, no. 8, pp. 545–558, 2023.
- [61] I. Mezić, "Analysis of fluid flows via spectral properties of

- the Koopman Operator,” *Annual Review of Fluid Mechanics*, vol. 45, pp. 357–378, 2013.
- [62] C. W. Rowley, I. Mezić, S. Bagheri, P. Schlatter, and D. S. Henningson, “Spectral analysis of nonlinear flows,” *Journal of Fluid Mechanics*, vol. 641, pp. 115–127, 2009.
- [63] S. L. Brunton, J. L. Proctor, and J. N. Kutz, “Discovering governing equations from data by sparse identification of nonlinear dynamical systems,” *Proc. Natl. Acad. Sci.*, vol. 113, no. 15, pp. 3932–3937, 2016.
- [64] B. Lusch, J. N. Kutz, and S. L. Brunton, “Deep learning for universal linear embeddings of nonlinear dynamics,” in *Proc. NeurIPS*, vol. 31, 2018.
- [65] N. Takeishi, Y. Kawahara, and T. Yairi, “Learning Koopman invariant subspaces for Dynamic Mode Decomposition,” in *Proc. NeurIPS*, vol. 30, 2017.
- [66] J. L. Proctor, S. L. Brunton, and J. N. Kutz, “Dynamic Mode Decomposition with control,” *SIAM J. Appl. Dyn. Syst.*, vol. 15, no. 1, pp. 142–161, 2016.
- [67] P. J. Baddoo, B. Herrmann, B. J. McKeon, J. N. Kutz, and S. L. Brunton, “Physics-Informed Dynamic Mode Decomposition,” *Proc. R. Soc. A*, vol. 479, no. 2271, p. 20220576, 2023.
- [68] J. Morton, F. D. Witherden, A. Jameson, and M. J. Kochenderfer, “Deep dynamical modeling and control of unsteady fluid flows,” *Neural Computation*, vol. 31, no. 12, pp. 2469–2501, 2019.
- [69] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, *et al.*, “Physics-informed machine learning,” *Nature Reviews Physics*, vol. 3, no. 6, pp. 422–440, 2021.
- [70] L. Lu, X. Meng, Z. Mao, and G. E. Karniadakis, “DeepXDE: A deep learning library for solving differential equations,” *SIAM Review*, vol. 63, no. 1, pp. 208–228, 2021.
- [71] S. Cuomo, V. S. Di Cola, F. Giampaolo, *et al.*, “Scientific machine learning through physics-informed neural networks: Where we are and what’s next,” *J. Sci. Comput.*, vol. 92, no. 3, p. 88, 2022.
- [72] S. Wang, Y. Teng, and P. Perdikaris, “Understanding and mitigating gradient flow pathologies in physics-informed neural networks,” *SIAM J. Sci. Comput.*, vol. 43, no. 5, pp. A3055–A3081, 2021.
- [73] S. Wang, S. Sankaran, H. Wang, and P. Perdikaris, “An expert’s guide to training physics-informed neural networks,” *SIAM J. Sci. Comput.*, vol. 45, no. 3, pp. A1473–A1501, 2023.
- [74] A. S. Krishnapriyan, A. Gholami, S. Zhe, R. M. Kirby, and M. W. Mahoney, “Characterizing possible failure modes in physics-informed neural networks,” *J. Comput. Phys.*, vol. 444, p. 110536, 2021.
- [75] Z. Mao, Y. Yu, G. E. Karniadakis, and L. Lu, “Physics-informed neural networks for wildfire spread simulation,” *J. Comput. Phys.*, vol. 507, p. 112978, 2024.
- [76] S. Markidis, “The old and the new: Can physics-informed deep-learning replace traditional linear solvers?” *Frontiers in Big Data*, vol. 4, p. 669097, 2021.
- [77] Z. Xi, W. Chen, X. Guo, *et al.*, “The rise and potential of large language model based agents: A survey,” arXiv preprint arXiv:2309.07864, 2023.
- [78] L. Wang, C. Ma, X. Feng, *et al.*, “A survey on large language model based autonomous agents,” *Frontiers of Computer Science*, vol. 18, no. 6, p. 186345, 2024.
- [79] J. S. Park, J. C. O’Brien, C. J. Cai, *et al.*, “Generative agents: Interactive simulacra of human behavior,” in *Proc. ACM UIST*, 2023.
- [80] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, “Reflexion: An autonomous agent with dynamic memory and self-reflection,” in *Proc. NeurIPS*, vol. 36, 2023.
- [81] T. Schick, J. Dwivedi-Yu, R. Dessi, *et al.*, “Toolformer: Language models can teach themselves to use tools,” in *Proc. NeurIPS*, vol. 36, 2023.
- [82] S. G. Patil, T. Zhang, X. Wang, and J. E. Gonzalez, “Gorilla: Large language model connected with massive APIs,” in *Proc. NeurIPS*, vol. 36, 2023.
- [83] Y. Gao, Y. Xiong, X. Gao, *et al.*, “Retrieval-Augmented Generation for large language models: A survey,” arXiv preprint arXiv:2312.10997, 2024.
- [84] M. Morsali and S. H. Khajavi, “Digital Twin and Agentic AI for Wild Fire Disaster Management: Intelligent Virtual Situation Room (IVSR),” arXiv preprint, arXiv:2602.08949, 2026.
- [85] C. Webb, M. Habibpour, M. H. Raha, *et al.*, “FIRE-VLM: A Vision-Language-Driven Reinforcement Learning Framework for UAV Wildfire Tracking in a Physics-Grounded Fire Digital Twin,” arXiv preprint, arXiv:2601.03449, 2026.
- [86] M. H. Raha, A. R. Tavakkoli, C. Webb, *et al.*, “FIRETWIN: Digital Twin Advancing Multi-Modal Sensing, Interactive Analytics for Wildfire Response,” arXiv preprint, arXiv:2510.18879, 2025.
- [87] I. Esparza, A. Battal, and A. Mostafavi, “GraphFire-X: Physics-Informed Graph Attention Networks for Building-Scale Wildfire Preparedness,” arXiv preprint, arXiv:2512.20813, 2025.
- [88] D. Michail, I. Davalas, *et al.*, “FireCastNet: Earth-as-a-Graph for Seasonal Fire Prediction,” arXiv preprint, arXiv:2502.01550, 2025 (v2).
- [89] K. Vogiatzoglou, C. Papadimitriou, V. Bontozoglou, and K. Ampountolas, “Physics-informed neural networks for parameter learning of wildfire spreading,” arXiv preprint, arXiv:2406.14591, 2024.
- [90] Z. Zhou, X. Wang, Y. Yan, *et al.*, “AIMNET: An IoT-Empowered Digital Twin for Continuous Gas Emission Monitoring and Early Hazard Detection,” arXiv preprint, arXiv:2512.06148. Accepted by IEEE Internet of Things Magazine, 2025.
- [91] Z. Shen and H. Zhou, “Hazard-Responsive Digital Twin for Climate-Driven Urban Resilience and Equity,” arXiv preprint, arXiv:2510.22941, 2025.
- [92] MapBiomas, “MapBiomas Fogo — Coleção de Mapas Anuais de Área Queimada,” 2024. [Online]. Available: <https://mapbiomas.org/>
- [93] I. Prapas, *et al.*, “Earth System Deep Learning Towards a Global Digital Twin of Wildfires,” in *EGU General Assembly*, 2023.